



RÉPUBLIQUE TUNISIENNE
MINISTÈRE DE L'ENSEIGNEMENT
SUPÉRIEUR
ET DE LA RECHERCHE SCIENTIFIQUE
Université de Tunis El Manar
Faculté des Sciences de Tunis
DÉPARTEMENT DES MATHÉMATIQUES



RAPPORT DE FIN D'ÉTUDES
Présenté en vue de l'obtention du
Diplôme National de Licence en Mathématique
Spécialité : Mathématique et Informatique

Présenté par :
Zouaoui Ahmed Anas

Encadré par :
Mr. Ben Abdejelil Slah Eddin

Sujet :
**Différents modes de convergence,
Méthode de Monte-Carlo et Applications**

Année Universitaire : 2023-2024

Remerciements

Tout d'abord, je suis profondément reconnaissant envers le Tout-Puissant Allah pour m'avoir accordé la détermination et la persévérance nécessaires pour achever ce projet.

Je suis reconnaissant à tous mes **Professeurs** de m'avoir bien accueilli avec leur bonne humeur et leur vivacité de cœur, et de répondre rigoureusement à toutes les questions que j'ai posées.

Mes mots de gratitude s'adressent à **Mr. Ben Abdejelil Slah Eddin**, mon encadreur pédagogique à la Faculté des Sciences de Tunis, pour l'intérêt qu'il a porté à ma modeste personne, pour ses conseils soignés, son suivi permanent et ses encouragements pendant les trois derniers mois.

Que les membres du jury trouvent ici ma profonde gratitude pour leur bienveillante considération à l'égard de ce travail. J'espère qu'il satisfait à leurs exigences élevées.

Je souhaite remercier **l'Équipe Pédagogique et Administrative** de la Faculté des Sciences de Tunis pour leur dévouement et leur implication sans relâche dans le but de m'offrir une excellente formation.

Pour finir, je tiens à adresser mes sincères remerciements à tous ceux qui, de manière essentielle ou indirecte, ont joué un rôle clé dans l'accomplissement de ce travail.

Dédicaces

Je suis reconnaissant de dédier ce modeste travail

À Dieu

pour m'avoir donné le courage et la capacité de surmonter toutes les difficultés et de vivre cet inoubliable événement.

À mon cher père Sami et à mon adorable mère Raja

en témoignage de mes sincères gratitude pour vos efforts inlassables et vos sacrifices inestimables pour satisfaire mes besoins durant toutes mes années d'études. Je m'efforcerai toujours davantage pour rester votre fierté. Que ce projet soit le reflet de votre immense soutien.

À mon cher frère Malek

qui a toujours été un exemple admirable dans ma vie.

À tous mes Amis

avec qui j'ai partagé des moments inoubliables et dont l'amitié a été une source de réconfort et de joie.

Table des Matières

Introduction générale	8
1 Espaces probabilisé	9
1.1 Introduction	9
1.2 Probabilité sur un espace fini	9
1.2.1 Expérience aléatoire	9
1.2.2 Univers	9
1.2.3 Événement	9
1.2.4 probabilité :	10
1.3 Tribu ou σ -algèbre	10
1.3.1 Tribu	10
1.3.2 Une algèbre	10
1.3.3 Tribu engendrée	11
1.3.4 Tribu borélienne	11
1.4 1.4 Espace mesurable	11
1.5 Espace mesuré	11
1.5.1 Espace mesuré	11
1.5.2 Mesures	12
1.5.3 Mesure de Lebesgue	12
1.6 Mesure de probabilité et espace probabilisé	13
1.6.1 Définition de la probabilité	13
1.6.2 Propriétés élémentaires	13
1.7 Probabilité conditionnelle	13
1.8 Indépendance	14
1.8.1 Indépendance de deux événements	14
1.8.2 Indépendance d'une famille finie ou infinie d'événements	14
1.8.3 Indépendance d'une famille de tribus	14
2 Variables aléatoires réelles	15
2.1 Généralités sur les variables aléatoires	15
2.1.1 Variable aléatoire	15
2.1.2 Loi de probabilité d'une variable aléatoire réelle X	15
2.2 Fonction de répartition	15
2.3 Densité de probabilité	16
2.4 Variable aléatoire discrète	16
2.4.1 Moments, variance, écart-type, covariance et coefficient de corrélation	17

2.4.2	vecteurs aléatoires	20
2.4.3	Lois usuelles	21
2.5	Variable aléatoire continue	24
2.5.1	Moments, variance, écart-type, covariance et coefficient de corrélation	24
2.5.2	vecteurs aléatoires	25
2.5.3	Lois usuelles :	26
2.6	Loi gaussienne, loi du chi-deux, loi de Student	33
2.6.1	Loi gaussienne :	33
2.6.2	Loi du chi-deux :	34
2.6.3	Loi de Student :	34
3	Convergence des variables aléatoires	37
3.1	Inégalités probabilistes	37
3.1.1	Inégalité de Markov	37
3.1.2	Inégalité de Bienaymé-Tchebychev	37
3.2	Les différentes modes de convergence	38
3.3	Fonction caractéristique	41
3.4	Convergence en loi	42
3.5	Lois des grands nombres	44
3.5.1	Loi faible des grands nombres	44
3.5.2	Loi forte des grands nombres	44
3.5.3	Théoreme limite centrale	44
4	Application des théorèmes de convergence (méthode de Monte-carlo)	46
4.1	Introduction	46
4.2	Principe de la méthode de Monte-carlo	46
4.3	Calcul d'intégrale par la méthode de Monte Carlo	46
4.4	Accélération par échantillonnage pondéré	47
4.5	Algorithmes	48
4.5.1	problèmes	48
4.6	Fondements des Méthodes Monte-Carlo en Physique Médicale	49
4.7	Environnement de travail	54
4.7.1	Anaconda	54
4.7.2	La bibliothèque NumPy	54
4.7.3	Matplotlib	54
	Conclusion et perspectives	55

Liste des tableaux

2.1 Lois discrètes usuelles	24
---------------------------------------	----

Liste des codes

4.1	Algorithme pour l'estimation de π	48
4.2	Estimation de π par la méthode de Monte Carlo en Python	49
4.3	Simulation Monte Carlo de l'Absorption de Dose en Physique des Particules	51
4.4	Simulation Monte Carlo de l'Absorption de Dose en Physique en python .	52

Introduction générale

La convergence des variables aléatoires et la méthode de Monte-Carlo sont des concepts fondamentaux dans le domaine de la probabilité et de la statistique, largement utilisés dans de nombreux domaines tels que la physique, l'économie, l'ingénierie et les sciences informatiques. Ces concepts offrent des outils puissants pour simuler des phénomènes complexes et prendre des décisions dans des situations d'incertitude.

La convergence de variables aléatoires implique l'étude du comportement limite de séquences de variables aléatoires lorsque les valeurs observées tendent vers l'infini. Il joue un rôle critique dans l'évaluation de la fiabilité des estimations statistiques. D'autre part, la méthode de Monte-Carlo est une approche probabiliste utilisée pour estimer des quantités en effectuant des simulations aléatoires. Elle tire son nom du célèbre casino de Monte-Carlo à Monaco, en raison de sa similitude avec les jeux de hasard.

Dans ce rapport, on va introduire les différentes notions de convergence pour une suite de variables aléatoires. Après avoir étudié les liens entre ces différentes notions, nous aborderons les techniques de simulation, ainsi que les applications pratiques dans divers domaines.

Le rapport est organisé comme suit :

- Dans le chapitre 1, on commence par une rappelle sur les différentes relations de probabilités utilisées.
- Le chapitre 2 est consacré sur les variables aléatoires réelles. Le long de ce chapitre, on définit les lois de probabilités d'une variable aléatoire réelle, d'un couple de variable aléatoire, la fonction de répartition et les moments d'ordre k d'une variable aléatoire réelle. On donne aussi dans ce chapitre les lois usuelles dans le cas d'une variable aléatoire discrète et d'une variable aléatoire continue.
- Dans le chapitre 3, on rappelle les différentes modes de convergences d'une variable aléatoire réelle et on donne les théorème de convergence.
- Le chapitre 4 introduit la méthode de Monte-Carlo, ses applications, et inclut l'écriture des algorithmes pour le calcul d'une intégrale par cette méthode ainsi que le code en langage Python.

Chapitre 1

Espaces probabilisés

1.1 Introduction

Historiquement, le calcul des probabilités s'est développé à partir du $XVII^e$ siècle autour des problèmes de jeux dans des situations où le nombre de cas possibles est fini. Les développements plus récents concernant des espaces non nécessairement finis nécessitent les outils techniques de la théorie de la mesure. Mais on peut introduire simplement sur les espaces finis toutes les notions importantes de probabilités sans avoir besoin de cet outillage.

1.2 Probabilité sur un espace fini

1.2.1 Expérience aléatoire

Définition 1.2.1. une expérience aléatoire est une expérience dont on ne peut pas prédire le résultat

Exemple 1.2.1. *On lance un dé cubique à six faces numérotées de 1 à 6. On ne peut pas prédire le résultat obtenu, il y a 6 cas possibles.*

Les différents résultats qu'on peut obtenir après une expérience aléatoire s'appellent les issues ou les résultats possibles.

1.2.2 Univers

Définition 1.2.2. l'univers associé à une expérience aléatoire est l'ensemble des issues de cette expérience aléatoire, il est noté Ω .

Un élément de Ω est une issue.

Exemple 1.2.2. *On lance deux dés et on additionne les points obtenus.*

$$\Omega = \{2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12\}$$

$$\text{card } \Omega = 11$$

1.2.3 Événement

Définition 1.2.3. Un événement aléatoire est lié à une expérience aléatoire, une fois l'expérience réalisée, on peut alors dire si l'événement a été réalisé ou non.

Un événement aléatoire A peut être identifié à la partie de Ω dont les éléments réalisent l'événement A .

Exemple 1.2.3. On lance un dé et on associe à cette expérience aléatoire l'univers Ω tq $\Omega = \{1, 2, 3, 4, 5, 6\}$

- Soit l'événement A_1 "on obtient un nombre pair"

$$A_1 = \{2, 4, 6\}$$

- Soit l'événement A_2 "le nombre obtenu est strictement inférieure à 2 "

$$A_2 = \{1\}$$

l'événement A_2 est appelé un événement élémentaire

- l'événement A_3 " le nombre obtenu est inférieure ou égal à 6 "

$$A_3 = \{1, 2, 3, 4, 5, 6\}$$

l'événement A_3 est appelé un événement certain

- l'événement A_4 "le nombre obtenu est négatif "

$$A_4 = \{\emptyset\}$$

l'événement A_4 est appelé un événement impossible

1.2.4 probabilité :

Définition 1.2.4. Une probabilité $\mathbb{P}$ sur un ensemble fini

$\Omega = \{w_1, w_2, \dots, w_n\}$ est une pondération $p_1, p_2, \dots, p_n$ des éléments de cet ensemble t.q

$$\forall 1 \leq k \leq n, p_k \geq 0 \text{ et } \sum_{k=1}^n p_k = 1$$

1.3 Tribu ou σ -algèbre

1.3.1 Tribu

Définition 1.3.1. Une tribu $\mathcal{A}$ sur Ω est une classe de parties de Ω qui vérifie les trois propriétés

suivantes :

i) $\emptyset, \Omega \in \mathcal{A}$

ii) $A \in \mathcal{A} \implies A^c \in \mathcal{A}$

iii) Si $(A_i)_{i \in I}$ est une famille dénombrable d'éléments de $\mathcal{A}$

alors $\bigcup_{i \in I} A_i$ et $\bigcap_{i \in I} A_i$ sont dans $\mathcal{A}$.

Un ensemble A est dénombrable s'il existe une bijection $f : \mathbb{N} \rightarrow A$, c'est-à-dire si l'on peut écrire $A = \{a_n : n \in \mathbb{N}\}$ avec des a_i deux à deux distincts.

Exemple 1.3.1. - $\{\emptyset, \Omega\}$ est la plus petite tribu sur Ω . On l'appelle tribu grossière.

- $\mathcal{P}$ est la plus grosse tribu sur Ω . On l'appelle tribu discrète.

- Si $A \subset \Omega, \{\emptyset, A, A^c, \Omega\}$ est une tribu sur Ω .

1.3.2 Une algèbre

Définition 1.3.2. On dit que $\mathcal{A} \subset \mathcal{P}(\Omega)$ est une algèbre si :

i) Si $A \neq \emptyset$

ii) A est stable par complémentaire "C"

(pour tout $A \in \mathcal{A}, A^c \in \mathcal{A}$)

iii) $\mathcal{A}$ est stable par union " $\bigcup$ " finie

(Pour tout $A_k \in \mathcal{A}$ avec $k \in [1, n]$, on a $\bigcup_{k=1}^n A_k \in \mathcal{A}$).

Proposition 1.3.1. *Si $\mathcal{A}_1$ et $\mathcal{A}_2$ sont 2 tribus en Ω , alors $\mathcal{A}_1 \cap \mathcal{A}_2$ est une tribu sur Ω . On ne peut rien dire sur $\mathcal{A}_1 \cup \mathcal{A}_2$*

1.3.3 Tribu engendrée

Définition 1.3.3. Soit ϕ une partie de $\mathcal{P}(\Omega)$, on appelle tribu engendrée par ϕ la plus petite tribu en Ω contenant ϕ , noté $\tau(\phi)$.

Exemple 1.3.2. La tribu ϕ engendrée par un événement A est : $\phi = \tau(A) = \{\Omega, \emptyset, A, \overline{A}\}$

1.3.4 Tribu borélienne

Définition 1.3.4. La tribu borélienne sur X est la tribu engendrée par les ouverts, c'est-à-dire la plus petite tribu contenant tous les ouverts dans $\mathbb{R}^d$, et notée $\mathcal{B}(X)$.

Exemple 1.3.3. pour $d=1$,
 $-\mathcal{B}_{\mathbb{R}}$ est la tribu engendrée par :

$$\phi_1 = \{]a, b[, a < b\}$$

$-\mathcal{B}_{\mathbb{R}}$ est la tribu engendrée par :

$$\phi_2 = \{]-\infty, a[, a \in \mathbb{R}\}$$

$-\mathcal{B}_{\mathbb{R}}$ est la tribu engendrée par :

$$\phi_3 = \{]b, +\infty[, b \in \mathbb{R}\}$$

1.4 Espace mesurable

Définition 1.4.1. Soit $\mathcal{A}$ est une tribu sur Ω , on appelle espace mesurable le couple $(\Omega, \mathcal{A})$.

Les éléments de Ω sont appelés ensembles mesurables.

Proposition 1.4.1. Soit $(\Omega, \mathcal{A})$ un espace mesurable et soit $(A_n)_{n \in \mathbb{N}}$ une famille de $\mathcal{A}$.

- 1) Si $(A_n)_{n \in \mathbb{N}}$ est croissante ($A_n \subset A_{n+1}$), alors $\lim_n \uparrow A_n = \bigcup_n A_n \in \mathcal{A}$
- 2) Si $(B_n)_{n \in \mathbb{N}}$ est décroissante ($B_{n+1} \subset B_n$), alors $\lim_n \downarrow B_n = \bigcap_n B_n \in \mathcal{A}$
- 3) $\limsup_n A_n = \bigcap_n \left(\bigcup_{k \geq n} A_k \right) \in \mathcal{A} / x$ appartient à l'infinité de A_n
- 4) $\liminf_n A_n = \bigcup_n \left(\bigcap_{k \geq n} A_k \right) \in \mathcal{A} / x$ appartient à tous les A_n sauf nombre finie.

1.5 Espace mesuré

1.5.1 Espace mesuré

Définition 1.5.1. Un espace Ω avec une-algèbre $\mathcal{A} \subset \mathbb{P}(\Omega)$ munie d'une mesure μ est appelé un espace mesuré, et sera souvent noté $(\Omega, \mathcal{A}, \mu)$.

1.5.2 Mesures

Définition 1.5.2. Soit $(\Omega, \mathcal{A})$ un espace mesurable. Une mesure sur Ω est une application :

$$\mu : \mathcal{A} \rightarrow [0, \infty]$$

vérifiant les propriétés suivantes :

i) $\mu(\emptyset) = 0$

ii) Si $(A_i)_{i \in \mathbb{N}}$ est une suite d'éléments de $\mathcal{A}$ et $A_i \cap A_j = \emptyset$ pour tout $i \neq j$ alors

$$\mu\left(\bigcup_{i=0}^{+\infty} A_i\right) = \sum_{i=0}^{+\infty} \mu(A_i)$$

Dans le cas particulier où $\mu(\Omega) = 1$, on dit que μ est une mesure de probabilité.

- Si $\mu(\Omega) < \infty$, on dira que μ est une mesure finie.

- Si $\exists (A_k)_k$ dans $\mathcal{A}$ qui forme une partition de Ω t.q,

$$\forall k \in \mathbb{N}, \mu(A_k) < \infty \text{ et } \mu(\Omega) = +\infty$$

alors on dit que μ est une σ -finie.

Exemple 1.5.1. Soit $(\Omega, \mathcal{P})$ un espace mesurable, soit $a \in \Omega$ fixé

On pose $\mu = \delta : A \rightarrow \{0, 1\}$

$$\delta_a(A) = 1_a(A) = \begin{cases} 1 & \text{si } a \in A, \\ 0 & \text{si } a \notin A. \end{cases} \quad (1.1)$$

μ est une mesure finie sur $(\Omega, \mathcal{P})$ appelée mesure de Dirac sur Ω .

Proposition 1.5.1. Soit $(\Omega, \mathcal{A}, \mu)$ un espace mesuré.

1) Si $A, B \in \mathcal{A}$ et $A \subset B$ alors $\mu(B) \geq \mu(A)$ (on dit que μ est croissante).

2) Si $A, B \in \mathcal{A}$, on a toujours

$$\mu(A \cup B) + \mu(A \cap B) = \mu(A) + \mu(B);$$

si $\mu(A \cap B) < \infty$ alors on peut aussi écrire

$$\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$$

3) Si $(A_i)_{i \in \mathbb{N}}$ sont telles que $A_i \in \mathcal{A}$, pour tout

$i \in \mathbb{N}$, alors on a

$$\mu\left(\bigcup_{i=0}^{+\infty} A_i\right) \leq \sum_{i=0}^{+\infty} \mu(A_i)$$

1.5.3 Mesure de Lebesgue

Définition 1.5.3. La mesure de Lebesgue sur $\mathbb{R}^n$ est l'unique mesure définie sur la tribu borélienne de $\mathbb{R}^n$ t.q,

$$\lambda\left(\prod_{i=1}^n [a_i, b_i]\right) = \prod_{i=1}^n (b_i - a_i)$$

Proposition 1.5.2. - Pour tout $x \in \mathbb{R}$, on a $\lambda(\{x\}) = 0$

- Si X_n est une suite de nombres réels, alors $\lambda(X_n : n \in \mathbb{N})$

- Pour tous réels $a \leq b$ on a

$$\lambda([a, b]) = \lambda(]a, b]) = \lambda([a, b[) = \lambda(]a, b[) = b - a$$

Exemple 1.5.2. $\mu = \lambda$ = mesure de Lebesgue

$$A =]2, +\infty[, \lambda(A) = +\infty$$

$$B =]1, +\infty[, \lambda(B) = +\infty$$

$$B \setminus A =]1, 2], \lambda(B \setminus A) = 1$$

1.6 Mesure de probabilité et espace probabilisé

1.6.1 Définition de la probabilité

Définition 1.6.1. Soit Ω muni d'une tribu $\mathcal{A}$. On appelle probabilité sur $(\Omega, \mathcal{A})$ une application $\mathbb{P} : \mathcal{A} \rightarrow [0,1]$ qui vérifie :

i) $\mathbb{P}(\Omega) = 1$

ii) Si $(A_i)_{i \in I}$ est une famille dénombrable d'éléments de $\mathcal{A}$ deux à deux disjoints ($\forall i \neq j \in I, A_i \cap A_j = \emptyset$) alors :

$$\mathbb{P}\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} \mathbb{P}(A_i)$$

le triplet $(\Omega, \mathcal{A}, \mathbb{P})$ s'appelle un espace de probabilité.

1.6.2 Propriétés élémentaires

- $\mathbb{P}(\emptyset) = 0$ mais $\mathbb{P}(A) = 0$ n'implique pas $A = \emptyset$

- $\mathbb{P}(\overline{A}) = 1 - \mathbb{P}(A)$

- $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$

- $\mathbb{P}\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} \mathbb{P}(A_i)$ (aucune hypothèse particulière sur les événements A_i)

1.7 Probabilité conditionnelle

Théorème 1.7.1 (formule des probabilités totales).

Soit $A_1, A_2, \dots, A_n$ une partition de l'univers Ω . Pour tout événement B on a
 $\mathbb{P}(B) = \mathbb{P}(A_1 \cap B) + \mathbb{P}(A_2 \cap B) + \dots + \mathbb{P}(A_n \cap B)$

Définition 1.7.1. Soit Ω muni d'une probabilité $\mathbb{P}$ et $A, B \subset \Omega$.

La probabilité conditionnelle de l'événement A sachant l'événement B est notée $\mathbb{P}(A|B)$ et définie par :

$$\mathbb{P}(A|B) = \begin{cases} \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} & \text{si } \mathbb{P}(B) > 0 \\ \mathbb{P}(A) & \text{sinon} \end{cases} \quad (1.2)$$

Exemple 1.7.1. Dans une famille qui comporte deux enfants, l'un est une fille. On cherche la probabilité que l'autre soit un garçon.

On choisit $\Omega = \{FF, FG, GF, GG\}$ où FG signifie que l'aîné des enfants est une fille et le second un garçon.

On note

$A = \{\text{un des enfants est un garçon}\} = \{FG, GF, GG\}$

$B = \{\text{un des enfants est une fille}\} = \{FF, FG, GF\}$

On a $\mathbb{P}(B) = \frac{3}{4}$ Comme $A \cap B = \{FG, GF\}$, $\mathbb{P}(A \cap B) = \frac{1}{2}$

Donc

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{1/2}{3/4} = \frac{2}{3}$$

Proposition 1.7.1 (formule de Bayes).

Soit $B_1, B_2, \dots, B_n$ une partition de Ω et $A \subset \Omega$ t.q $\mathbb{P}(A) > 0$, alors pour tout $1 \leq i \leq n$

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_{j=1}^n \mathbb{P}(A|B_j)\mathbb{P}(B_j)}$$

Démonstration. $(B_k)_k$ une partition de Ω t.q $\forall k \in \mathbb{N}, \mathbb{P}(A_k) \neq 0$

Pour tout événement A on a

$$\mathbb{P}(A) = \sum_k \mathbb{P}(A|B_k)\mathbb{P}(B_k)$$

d'après la formule des probabilités totales

$$\mathbb{P}(A \cap B_k) = \mathbb{P}(A|B_k)\mathbb{P}(B_k) = \mathbb{P}(B_k|A)\mathbb{P}(A) \text{ D'où le resultat.} \quad \square$$

1.8 Indépendance

1.8.1 Indépendance de deux événements

Définition 1.8.1. Soit Ω muni d'une probabilité $\mathbb{P}$. Deux événements A et B sont dits indépendants si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \times \mathbb{P}(B)$$

Remarque 1.8.1. L'indépendance de A et B se caractérise aussi par les relations

$$\mathbb{P}(A|B) = \mathbb{P}(A) \text{ ou } \mathbb{P}(B|A) = \mathbb{P}(B)$$

1.8.2 Indépendance d'une famille finie ou infinie d'événements

Définition 1.8.2. n événements $A_1, A_2, \dots, A_n$ sont dits indépendants si, $\forall i \subset \{1, \dots, n\}$

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i)$$

1.8.3 Indépendance d'une famille de tribus

Définition 1.8.3. Puisque la famille d'événements $\{\Omega, \emptyset, A_i, \overline{A_i}\}$ associée à l'événement A_i est la tribu engendrée par A_i , nous allons éteindre la définition précédente d'une famille de tribus $(\mathcal{F}_i)_{i \in I}$.

Une famille $(\mathcal{F}_i)_{i \in I}$ est dite indépendante si pour tout ensemble fini $(i_1, \dots, i_n) \in I$, on a

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k})$$

Exemple 1.8.1. Soit $\Omega = \{\mathcal{W}_1, \mathcal{W}_2, \mathcal{W}_3, \mathcal{W}_4\}$ muni de la probabilité uniforme, et soit $A_1 = \{\mathcal{W}_1, \mathcal{W}_2\}$, $A_2 = \{\mathcal{W}_2, \mathcal{W}_3\}$ et $A_3 = \{\mathcal{W}_1, \mathcal{W}_3\}$ alors, on a

$$\mathbb{P}(A_1) = \mathbb{P}(A_2) = \mathbb{P}(A_3) = \frac{1}{2}$$

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1 \cap A_3) = \mathbb{P}(A_2 \cap A_3) = \frac{1}{4}$$

$\Rightarrow$ il y a indépendance deux à deux.

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(\emptyset) \neq \mathbb{P}(A_1) \cap \mathbb{P}(A_2) \cap \mathbb{P}(A_3) = \frac{1}{8}$$

$\Rightarrow$ la famille de A_1, A_2 et A_3 n'est pas indépendante.

Chapitre 2

Variables aléatoires réelles

2.1 Généralités sur les variables aléatoires

2.1.1 Variable aléatoire

Définition 2.1.1. On appelle variable aléatoire toute application mesurable $X : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}^d, \mathbb{B})$ où $\mathbb{B}$ est la tribu de Borel de $\mathbb{R}$.

Les variables aléatoires sont des outils fondamentaux en théorie des probabilités et en statistiques. Elles permettent de représenter de manière formelle les résultats possibles d'une expérience aléatoire, qu'il s'agisse de lancer de dés, de mesures physiques, ou de phénomènes complexes comme le comportement financier des marchés. En modélisant la variabilité inhérente à ces phénomènes, les variables aléatoires nous permettent d'analyser et de prédire des comportements probabilistes, d'évaluer des risques, et de prendre des décisions éclairées dans des domaines aussi divers que la finance, la médecine, ou la météorologie.

2.1.2 Loi de probabilité d'une variable aléatoire réelle X

Définition 2.1.2. On appelle loi de la variable aléatoire X la mesure-image de la probabilité $\mathbb{P}_X$. On dit aussi loi de probabilité de X. Cela signifie que pour tout borélien B de $\mathbb{R}^d$

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B)$$

Donc

$$\mathbb{P}_X(B) = \mathbb{P}(w/X(w) \in \mathbb{B}) = \mathbb{P}(X^{-1}(B))$$

2.2 Fonction de répartition

Définition 2.2.1. Soit X une variable aléatoire réel, on appelle fonction de répartition de X la fonction F_X de $\mathbb{R}$ dans $[0,1]$ définie par, pour tout $t \in \mathbb{R}$,

$$F_X(t) = \mathbb{P}(X < t)$$

alors la relation entre la fonction de répartition F_x et la fonction densité de probabilité $f(x)$ est,

pour tout $t \in \mathbb{R}$

$$F_X(t) = \mathbb{P}(X < t) = \int_{-\infty}^t f(x)dx$$

Soit x une variable aléatoire absolument continue de densité f et de fonction de répartition F_x , alors :

pour tout $a, b \in \mathbb{R}$ avec $a < b$

$$\mathbb{P}(a \leq x \leq b) = F_x(b) - F_x(a) = \int_a^b f(x)dx$$

Proposition 2.2.1. Soit F_x la fonction de répartition d'une variable aléatoire absolument continue X alors :

- 1) F_x est continue sur $\mathbb{R}$, dérivable en tout point où f est continue et alors $F'_x = f$
- 2) F_x est continue sur $\mathbb{R}$
- 3) F_x est à valeurs dans $[0, 1]$
- 4) $\lim_{x \rightarrow +\infty} F(x) = 1$ et $\lim_{x \rightarrow -\infty} F(x) = 0$

2.3 Densité de probabilité

Définition 2.3.1. Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace de probabilité.

On dit que la variable aléatoire $X : \Omega \rightarrow \mathbb{R}$ possède la densité $f : \mathbb{R} \rightarrow \mathbb{R}$ si :

$\forall a < b \in \mathbb{R}$

$$\mathbb{P}(a < X \leq b) = \int_a^b f(x)dx$$

Remarque 2.3.1. Une variable aléatoire X définie sur $(\Omega, \mathcal{A}, \mathcal{P})$ est dite absolument continue, s'il existe une fonction densité de probabilité f telle que :

pour tout $t \in \mathbb{R}$

$$P(X < t) = \int_{-\infty}^t f(x)dx$$

2.4 Variable aléatoire discrète

On appelle variable aléatoire discrète une application

$$X : \Omega \longrightarrow E$$

où E est un ensemble fini ou dénombrable

Proposition 2.4.1. Soit X une variable aléatoire discrète, alors $([X = x])_{x \in \Omega}$ est un système complet d'événements. En particulier,

$$\sum_{x \in X(\Omega)} \mathbb{P}(X = x) = 1$$

Démonstration. X est une variable aléatoire discrète donc $\forall x \in X(\Omega)$, $[X = x] \in \mathcal{A}$.

Si x et y sont deux éléments distincts de $X(\Omega)$, alors les événements $[X = x]$ et $[X = y]$

sont incompatibles. De plus, $\bigcup_{x \in X(\Omega)} [X = x] = [x \in X(\Omega)] = \Omega$

donc

$$\sum_{x \in X(\Omega)} \mathbb{P}(X = x) = \mathbb{P}\left(\bigcup_{x \in X(\Omega)} [X = x]\right) = \mathbb{P}(\Omega) = 1$$

□

2.4.1 Moments, variance, écart-type, covariance et coefficient de corrélation

1-Moments

Définition 2.4.1. Soit X une variable aléatoire réelle définie sur un espace probabilisé $(\Omega, \mathcal{A}, \mathcal{P})$ fini.

Elle est dite intégrable si $(\sum_{x \in X(\Omega)} |x| \mathbb{P}(X=x) < +\infty)$. Dans ce cas, on définit son espérance par :

$$\mathbb{E}(X) = \sum_{x \in X(\Omega)} x \mathbb{P}(X = x)$$

Proposition 2.4.2. *Linéarité : si X et Y sont deux variables discrètes à valeurs réelles intégrables et $\lambda \in \mathbb{R}$, alors $X + \lambda Y$ est intégrable et*

$$\mathbb{E}(X + \lambda Y) = \mathbb{E}(X) + \lambda \mathbb{E}(Y)$$

Théorème 2.4.1 (Théorème de Transfert).

Soit X une variable aléatoire sur $(\Omega, \mathcal{A}, \mathcal{P})$ et soit $f : F \rightarrow \mathbb{R}$ une application.

la variable $f(X)$ est intégrable si et seulement si $(\sum_{x \in X(\Omega)} |f(x)| \mathbb{P}(X = x) < +\infty)$

et alors,

$$\mathbb{E}(f(X)) = \sum_{x \in X(\Omega)} f(x) \mathbb{P}(X = x)$$

Démonstration. On pose $f(x) = y$ tq $y \in \mathbb{R}$

$$\text{on a } \mathbb{E}(f(X)) = \sum_{x \in X(\Omega)} y \mathbb{P}(f(X) = y)$$

or

$$\{f(X) = y\} = \{X \in f^{-1}(y)\}$$

$$= \bigcup_{x \in X(\Omega)} \{X = x\}$$

d'où

$$\mathbb{P}(f(X) = y) = \sum_{x \in X(\Omega)} \mathbb{P}(X = x)$$

alors

$$\mathbb{E}(f(X)) = \sum_{x \in X(\Omega)} f(x) \mathbb{P}(X = x)$$

□

2- Variance

Définition 2.4.2. Soit X une variable aléatoire réelle sur $(\Omega, \mathcal{A}, \mathcal{P})$.

X est dite de carré intégrable si X^2 est intégrable si $(\sum_{x \in F} x^2 \mathbb{P}(X = x) < +\infty)$

Dans ce cas, on définit la variance de X par :

$$V(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

Théorème 2.4.2.

$$V(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$$

Démonstration.

$$\begin{aligned} V(X) &= \mathbb{E}((X - \mathbb{E}(X))^2) \\ &= \mathbb{E}(X^2 - 2X\mathbb{E}(X) + \mathbb{E}(X)^2) \\ &= \mathbb{E}(X^2) - 2\mathbb{E}(X)\mathbb{E}(X) + (\mathbb{E}(X))^2 \\ &= \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \end{aligned}$$

□

Proposition 2.4.3. Soient $a \in \mathbb{R}, b \in \mathbb{N}$ et $\Omega \longrightarrow \mathbb{N}$ une variable aléatoire alors,

$$*V(aX + b) = a^2V(X)$$

$$*V(aX) = a^2V(X)$$

Démonstration.

$$\begin{aligned} V(aX + b) &= \mathbb{E}((aX + b)^2) - (\mathbb{E}(aX + b))^2 \\ &= \mathbb{E}((aX)^2 + b^2 + 2abX) - (a\mathbb{E}(X) + b)^2 \\ &= a^2\mathbb{E}(X^2) + 2ab\mathbb{E}(X) - (a^2(\mathbb{E}(X))^2 + b^2 + 2ab\mathbb{E}(X)) \\ &= a^2(\mathbb{E}(X^2) - (\mathbb{E}(X))^2) \\ &= a^2V(X) \end{aligned}$$

□

3- écart-type

Définition 2.4.3. Soit X une variable réelle sur $(\Omega, \mathcal{A}, \mathcal{P})$.

L'écart-type de x est une réelle noté $\sigma(X) = \sqrt{V(X)}$

Proposition 2.4.4. Soit X une variable aléatoire de loi de probabilité $(\Omega, \mathcal{A}, \mathcal{P})$ et a, b deux réels.

$$\sigma(aX + b) = |a|\sigma(X)$$

Démonstration. $\implies \sigma(X) = \sqrt{a^2V(X)} = |a|\sigma(X)$

□

Théorème 2.4.3. Soit X une variable aléatoire réelle sur $(\Omega, \mathcal{A}, \mathcal{P})$ alors,

* $X - \mathbb{E}(X)$ est centrée

* X est dite réduite si et seulement si $V(X)=1$

4-Covariance

Définition 2.4.4. Soient X et Y deux variables aléatoires réelles sur $(\Omega, \mathcal{A}, \mathcal{P})$. La covariance de X et Y est le réel :

$$\mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

Théorème 2.4.4. Soient X et Y deux variables aléatoires réelles sur $(\Omega, \mathcal{A}, \mathcal{P})$ alors

$$\text{cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

Démonstration.

$$\begin{aligned} \text{cov}(X, Y) &= \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) \\ &= \mathbb{E}(XY - X\mathbb{E}(Y) - \mathbb{E}(X)Y + \mathbb{E}(X)\mathbb{E}(Y)) \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) - \mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(X)\mathbb{E}(Y) \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \end{aligned}$$

□

Matrice de covariance

Soit $X = (X_1, \dots, X_d)$ un vecteur aléatoire à valeurs $\mathbb{R}^d$ (non nécessairement à densité) dont les composantes sont de carré intégrable.

On appelle matrice de covariance du vecteur X la matrice K^X de dimension $d \times d$ t.q $\forall 1 \leq i, j \leq d$

$$\begin{aligned} K_{ij}^X &= \text{cov}(X_i, X_j) \\ &= \mathbb{E}[(X_i - \mathbb{E}(X_i))(X_j - \mathbb{E}(X_j))] \end{aligned}$$

Propriété 1. 1) $\text{cov}(Y, Y) = V(Y)$ et les éléments diagonaux de la matrice de covariance K^X sont les variances des composantes de X .

2) $\text{cov}(Y, Z) = \mathbb{E}(YZ) - \mathbb{E}(Y)\mathbb{E}(Z)$

3) Si Y et Z sont indépendantes $\text{cov}(Y, Z) = 0$

4) La matrice de covariance K^X est symétrique et positive.

5- coefficient de corrélation

Définition 2.4.5. Soient X et Y des variables aléatoires sur $(\Omega, \mathcal{A}, \mathcal{P})$.

Si X et Y admettent une covariance et des variances non nulles, alors leur coefficient de corrélation linéaire est défini par :

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{V(X)V(Y)}}$$

Proposition 2.4.5.

1) Les variables aléatoires X et Y sont dites non corrélées si $\text{cov}(X, Y) = 0$

Elles sont dites corrélées si $\text{cov}(X, Y) \neq 0$

2) $\rho(X, Y) \in [-1, 1]$

2.4.2 vecteurs aléatoires

1- Loi conjointe

Définition 2.4.6. Soit $(\Omega, \mathcal{A}, \mathcal{P})$ un espace probabilisé fini.

Soient E et F deux ensembles

Soient $X : \Omega \rightarrow E$, $Y : \Omega \rightarrow F$, deux variables aléatoires

la loi conjointe des variables X et Y est de la loi de probabilité du couple (X,Y) càd $\mathbb{P}_{(X,Y)}$

$$\mathbb{P}_{(X,Y)} : \mathbb{P}(X(\Omega)) \times \mathbb{P}(Y(\Omega)) \rightarrow [0,1]$$

$$(A, B) \rightarrow \mathbb{P}(A, B) = \mathbb{P}((X \in A) \cap (Y \in B))$$

$$= \mathbb{P}(X \in A, Y \in B)$$

$$(X \in A) = \{w \in \Omega \text{ tq } X(\Omega) \in A\} \in \mathbb{P}(\Omega)$$

$$(Y \in B) = \{w \in \Omega \text{ tq } Y(\Omega) \in B\} \in \mathbb{P}(\Omega)$$

2- Loi marginale

Définition 2.4.7. Soit (x,y) un couple de variables aléatoires défini sur $(\Omega, \mathcal{A}, \mathcal{P})$.

La première loi marginale est la loi de x et la deuxième loi marginale est la loi de y.

Exemple 2.4.1. Soit (x,y) un couple de variables aléatoires défini sur $(\Omega, \mathcal{A}, \mathcal{P})$.

$$X : \Omega \rightarrow \{0,1\}$$

$$Y : \Omega \rightarrow \{0,1\}$$

On suppose que la loi du couple (X,Y) est donnée par le tableau suivant :

$X Y$	0	1
0	$\frac{1}{6}$	$\frac{1}{4}$
1	$\frac{1}{3}$	$\frac{1}{4}$

$$\Rightarrow \mathbb{P}(X = 0, Y = 0) = \frac{1}{6}$$

$$\Rightarrow \mathbb{P}(X = 1, Y = 0) = \frac{1}{3}$$

$$\Rightarrow \mathbb{P}(X = 1, Y = 1) = \frac{1}{4}$$

$$\Rightarrow \mathbb{P}(X = 0, Y = 1) = \frac{1}{4}$$

$$\Omega = (Y = 0) \cup (Y = 1)$$

$$\mathbb{P}(X = 0) = \mathbb{P}(X = 0 \cap \Omega)$$

$$= \mathbb{P}((X = 0) \cap ((Y = 0) \cup (Y = 1)))$$

$$= \mathbb{P}((X = 0) \cap (Y = 0)) \cup \mathbb{P}((X = 0) \cap (Y = 1))$$

$$= \mathbb{P}(X = 0, Y = 0) + \mathbb{P}(X = 0, Y = 1)$$

$$= \frac{1}{6} + \frac{1}{4}$$

$$= \frac{5}{12}$$

$$\mathbb{P}(X=1) = \mathbb{P}(X=1, Y=1) + \mathbb{P}(X=0, Y=1)$$

$$= \frac{1}{3} + \frac{1}{4} = \frac{7}{12}$$

2.4.3 Lois usuelles

1- Loi de Bernoulli

Définition 2.4.8. On considère une expérience dont le résultat ne peut prendre que deux valeurs appelées, par convention, succès ou échec : un candidat est reçu ou non à un examen, une pièce usinée est bonne ou défectueuse, une porte est ouverte ou fermée...

À une expérience de ce type, est associée une variable aléatoire X prenant la valeur 1 pour le succès et la valeur 0 pour l'échec, avec les probabilités respectives p et $(1 - p) = q$. La loi de probabilité d'une variable de Bernoulli X , notée $\mathcal{B}(p)$, est définie par :

$$\mathbb{P}(X = 1) = p$$

$$\mathbb{P}(X = 0) = 1 - p = q$$

On a alors :

$$\forall x \in \{0, 1\}, \mathbb{P}(X = x) = p^x(1 - p)^{1-x}$$

Ses moments sont :

$$\mathbb{E}(X) = p$$

$$V(X) = p(1 - p) = pq$$

2- Loi binomiale

Définition 2.4.9. Soit X la variable aléatoire qui “ compte ” le nombre de succès au cours de n épreuves.

- Si au cours de n épreuves, on obtient k succès, on obtient également $(n - k)$ échecs.

La probabilité de réalisation d'un tel événement est égale à $p^k(1 - p)^{n-k}$ (les épreuves sont indépendantes).

- Il y a différentes façons d'obtenir k succès au cours de n épreuves, les épreuves sont indépendantes les unes des autres. Le nombre de réalisations possibles de l'événement “ obtenir k succès au cours de n épreuves ” est le nombre de combinaisons sans répétitions de n objets pris k à k , soit :

$$C_n^k = \binom{n}{k} = \frac{n!}{k!(n - k)!}$$

D'où :

$$\mathbb{P}(X = k) = C_n^k p^k (1 - p)^{n-k} = \frac{n!}{k!(n - k)!} p^k (1 - p)^{n-k}$$

La loi de la variable X est appelée loi binomiale de paramètres (n, p) , notée $\mathcal{B}(n, p)$.

Une variable binomiale est égale à la somme de n variables aléatoires indépendantes de Bernoulli.

Ses moments sont :

$$\mathbb{E}(X) = np$$

$$V(X) = np(1 - p) = npq$$

3- Loi géométrique

Définition 2.4.10. La loi géométrique est la loi de la variable Y “ loi du nombre d’essais nécessaires ”, pour qu’un événement de probabilité p apparaisse pour la première fois, les hypothèses étant les mêmes que pour la loi binomiale, en particulier, la probabilité p reste constante au cours des essais :

$$\forall k \in \mathbb{N}^*, \mathbb{P}(Y = k) = p(1 - p)^{k-1}$$

Ses moments sont :

$$\mathbb{E}(Y) = \frac{1}{p}$$

$$V(Y) = \frac{1-p}{p^2}$$

Démonstration.

$$\mathbb{E}(X) = \sum_{k=1}^n k \mathbb{P}(X = k) = \sum_{k=1}^n k p (1 - p)^{k-1}$$

Or on a $\sum_{k=1}^n k x^{k-1} = \frac{1}{(1-x)^2}$

Donc

$$\sum_{k=1}^n k (1 - p)^{k-1} = \frac{1}{(1 - (1 - P))^2} = \frac{1}{p^2}$$

d’où

$$\mathbb{E}(X) = \frac{1}{p}$$

Et on a $V(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$

et

$$\mathbb{E}(X^2) = \sum_{k=1}^n k^2 \mathbb{P}(X = k) = p \sum_{k=1}^n k^2 (1 - p)^{k-1}$$

Or $\sum_{k=1}^n k^2 x^{k-1} = \frac{1+x}{(1-x)^3}$

Donc

$$\sum_{k=1}^n k^2 (1 - p)^{k-1} = \frac{2 + p}{(1 - (1 - P))^3} = \frac{2 - p}{p^3}$$

d’où $\mathbb{E}(X^2) = \frac{2-p}{p^2}$

alors

$$V(X) = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

□

4- Loi de Poisson

Définition 2.4.11. La loi de Poisson de paramètre λ est la loi d’une variable aléatoire discrète réelle X , prenant toutes les valeurs entières non négatives, avec les probabilités : $\forall k \in [0, +\infty[$

$$\mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Ses moments sont :

$$\mathbb{E}(X) = V(X) = \lambda$$

Démonstration. L'espérance $\mathbb{E}(X)$ d'une variable aléatoire X suivant une loi de Poisson est définie comme suit :

$$\begin{aligned}\mathbb{E}(X) &= \sum_{k=0}^{+\infty} k \frac{e^{-\lambda} \lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{+\infty} \frac{\lambda^k}{(k-1)!} \\ &= e^{-\lambda} \lambda \sum_{k=1}^{+\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ &= e^{-\lambda} \lambda \sum_{k=0}^{+\infty} \frac{\lambda^k}{(k)!}\end{aligned}$$

or $\sum_{k=0}^{+\infty} \frac{\lambda^k}{(k)!} = e^\lambda$
donc

$$\mathbb{E}(X) = e^{-\lambda} \lambda e^\lambda = \lambda$$

pour calculer la variance, on a

$$V(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$$

et

$$\begin{aligned}\mathbb{E}(X(X-1)) &= \mathbb{E}(X^2) - \mathbb{E}(X) = \sum_{k=0}^{+\infty} k(k-1) \frac{e^{-\lambda} \lambda^k}{k!} \\ &= \lambda^2 e^{-\lambda} \sum_{k=2}^{+\infty} \frac{\lambda^{k-2}}{(k-2)!} \\ &= \lambda^2 e^{-\lambda} \sum_{k=0}^{+\infty} \frac{\lambda^k}{k!} \\ &= \lambda^2 e^{-\lambda} e^\lambda = \lambda^2\end{aligned}$$

donc $\mathbb{E}(X^2) = \lambda^2 + \lambda$

Par conséquent, la variance est

$$V(X) = \lambda^2 + \lambda - \lambda^2 = \lambda$$

□

resumé :

Ce tableau ci-dessous résume les principales lois usuelles pour les variables aléatoires discrètes, en fournissant leur fonction de probabilité, ainsi que leurs valeurs d'espérance et de variance.

TABLE 2.1 – Lois discrètes usuelles

Nom	Loi	$\mathbb{E}(X)$	$\text{Var}(X)$	$g_X(s)$
Bernoulli $\mathcal{B}(p)$	$\mathbb{P}(X = 1) = p = 1 - \mathbb{P}(X = 0)$	p	$p(1 - p)$	$1 - p + ps$
binomiale $\mathcal{B}(n, p)$	$\forall 0 \leq k \leq n, \mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$	np	$np(1 - p)$	$(1 - p + ps)^n$
Poisson $\mathcal{P}(\lambda)$	$\forall n \in \mathbb{N}, \mathbb{P}(X = n) = \exp(-\lambda) \frac{\lambda^n}{n!}$	λ	λ	$e^{\lambda(s-1)}$
géométrique $\mathcal{Geo}(p)$	$\forall n \in \mathbb{N}^*, \mathbb{P}(X = n) = p(1 - p)^{n-1}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	$\frac{ps}{1-(1-p)s}$

2.5 Variable aléatoire continue

Une variable aléatoire continue prend des valeurs sur un ensemble infini non dénombrable de points, elle décrit par exemple la durée de vie d'une batterie de voiture...
Il existe une fonction f positive, définie pour toute valeur $x \in \mathbb{R}$ et vérifiant, pour toute partie A de $\mathbb{R}$, la propriété :

$$\mathbb{P}(X \in A) = \int_A f(x) dx$$

et telle que :

$$\int_{\mathbb{R}} f(x) dx = 1$$

La fonction f est la densité de probabilité de la variable aléatoire X .

2.5.1 Moments, variance, écart-type, covariance et coefficient de corrélation

1- Moments

Définition 2.5.1. La variable aléatoire $X : \Omega \rightarrow \mathbb{R}$ qui possède la densité f est dite intégrable si

$\int_{\mathbb{R}} |x| f(x) dx < +\infty$ et alors on définit son espérance par :

$$\mathbb{E}(X) = \int_{\mathbb{R}} x f(x) dx$$

Théorème 2.5.1 (Théorème de Transfert).

Soit X une variable aléatoire sur $(\Omega, \mathcal{A}, \mathcal{P})$ et soit $f : \mathbb{R} \rightarrow \mathbb{R}^+$ une application mesurable de densité $g(X)$. le théorème de transfert donne :

$$\mathbb{E}(f(X)) = \int_{\mathbb{R}} f(x) g(x) dx$$

2- Variance

Définition 2.5.2. La variable aléatoire $X : \Omega \rightarrow \mathbb{R}$ qui possède la densité f est dite de carré intégrable si

$\mathbb{E}(X^2) = \int_{\mathbb{R}} x^2 f(x) dx < +\infty$, alors on définit sa variance par :

$$V(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2 = \mathbb{E}((X - \mathbb{E}(X))^2)$$

3- écart-type

$$\sigma(X) = \sqrt{V(X)}$$

4- covariance

$$\mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

5- Coefficient de corrélation

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{V(X)V(Y)}}$$

2.5.2 vecteurs aléatoires

Théorème 2.5.2 (2.5.1 Théorème de Fubini).

Soit $f : \mathbb{R}^2 \rightarrow \mathbb{R}$

Si f est positive ou borné ou intégrable

$$\int_{\mathbb{R}^2} f(x, y) dx dy = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} f(x, y) dx \right) dy = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} f(x, y) dy \right) dx$$

Exemple 2.5.1. Soit $f : [0, +\infty[\rightarrow [0, +\infty[$

$$\begin{aligned} I &= \int_{[0, +\infty[\times [0, +\infty[} \frac{f(x+y)}{x+y} dx dy \\ &= \int_{[0, +\infty[} \left(\int_{[0, +\infty[} \frac{f(x+y)}{x+y} dy \right) dx \end{aligned}$$

On pose

$$z = x + y \longrightarrow y = z - x$$

$$\implies dz = dy$$

donc

$$\begin{aligned} I &= \int_{[0, +\infty[} \left(\int_{[0, +\infty[} \frac{f(z)}{z} dz \right) dx \\ &= \int_{[0, +\infty[} \left(\int_{[0, +\infty[} 1_{(z \geq x)} \frac{f(z)}{z} dz \right) dx \\ &= \int_{[0, +\infty[} \frac{f(z)}{z} \left(\int_{[0, +\infty[} 1_{(z \geq x)} dx \right) dz \\ &= \int_{[0, +\infty[} \frac{f(z)}{z} dz \end{aligned}$$

1- Loi conjointe

Définition 2.5.3. La loi conjointe de variables aléatoires (X, Y) continues sur $(\Omega, \mathcal{A}, \mathcal{P})$ peut être caractérisée par $f_{X,Y}(x, y)$.

C'est à dire il suffit de connaître la densité conjointe $f_{X,Y}(x, y)$ de X, Y vérifiant :

$$\mathbb{P}(X, Y \in A) = \int \int_A f_{X,Y}(x, y) dx dy$$

2- Loi marginale

Définition 2.5.4. Soient (X, Y) deux variables aléatoires sur $(\Omega, \mathcal{A}, \mathcal{P})$ avec densité $f_{X,Y}(x, y)$. On appelle densité marginale de X la fonction :

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy$$

et la densité marginale de Y la fonction :

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx$$

2.5.3 Lois usuelles :

1- Loi Uniforme

Définition 2.5.5. Une variable aléatoire réelle X , suit une loi uniforme sur l'intervalle $[a, b]$, si sa loi de probabilité admet une densité f égale à :

$$f(x) = \frac{1}{b-a} 1_{[a,b]}$$

Sa fonction de répartition :

$$F(x) = \begin{cases} = 0 & \text{si } x < a \\ = (x-a)/(b-a) & \text{si } a \leq x < b \\ = 1 & \text{si } x \geq b \end{cases} \quad (2.1)$$

Ses moments sont :

$$\begin{aligned} \mathbb{E}(X) &= \frac{(a+b)}{2} \\ V(X) &= \frac{(b-a)^2}{12} \end{aligned}$$

Démonstration. Soit L'espérance $\mathbb{E}(X)$ est calculée comme suit :

$\mathbb{E}(X) = \int_a^b x f(x) dx$ où $f(x)$ est la densité de probabilité de X , c'est à dire $\frac{1}{b-a}$ donc

$$\begin{aligned} \mathbb{E}(X) &= \int_a^b x \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b \\ &= \frac{b^2 - a^2}{2(b-a)} \\ &= \frac{b+a}{2} \end{aligned}$$

donc $\mathbb{E}(X) = \frac{a+b}{2}$

et pour la variance on a :

$$\begin{aligned}
 V(X) &= \mathbb{E}\left[\left(X - \frac{a+b}{2}\right)^2\right] = \int_a^b \frac{1}{b-a} \left(x - \frac{a+b}{2}\right)^2 dx \\
 &= \frac{1}{b-a} \int_a^b \left(x - \frac{a+b}{2}\right)^2 dx \\
 &= \frac{1}{b-a} \int_a^b \left(x^2 - x(a+b) + \frac{(a+b)^2}{4}\right) dx \\
 &= \frac{1}{b-a} \int_a^b x^2 dx - \frac{a+b}{b-a} \int_a^b x dx + \frac{(a+b)^2}{4(b-a)} \\
 &= \frac{1}{b-a} \left[\frac{x^3}{3}\right]_a^b - \frac{a+b}{b-a} \left[\frac{x^2}{2}\right]_a^b + \frac{(a+b)^2}{4(b-a)} \\
 &= \frac{b^3 - a^3}{3(b-a)} - \frac{(a+b)(b^2 - a^2)}{2(b-a)} + \frac{(a+b)^2}{4(b-a)} = \frac{(b-a)^2}{12}
 \end{aligned}$$

□

2- Loi exponentielle

Définition 2.5.6. Une variable aléatoire réelle positive X suit la loi exponentielle, de paramètre λ positif, si sa densité de probabilité est donnée par :

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{sinon} \end{cases} \quad (2.2)$$

Sa fonction de répartition est donnée par :

$$F(x) = \begin{cases} 1 - e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{sinon} \end{cases} \quad (2.3)$$

Ses moments sont :

$$\begin{aligned}
 \mathbb{E}(X) &= \frac{1}{\lambda} \\
 V(X) &= \frac{1}{\lambda^2}
 \end{aligned}$$

Démonstration. L'espérance $\mathbb{E}(X)$ d'une variable aléatoire X est définie comme suit :
 $\mathbb{E}(X) = \int_0^{+\infty} x f(x) dx$ où $f(x)$ est la fonction de densité de probabilité de X , c'est à dire,
 $f(x) = \lambda e^{-\lambda x}$
 donc

$$\mathbb{E}(X) = \int_0^{+\infty} x \lambda e^{-\lambda x} dx$$

En utilisant la formule d'intégration par parties :

$$u = x \longrightarrow du = 1$$

$$dv = \lambda e^{-\lambda x} \longrightarrow v = -e^{-\lambda x}$$

donc, nous obtenons :

$$\mathbb{E}(X) = [-x e^{-\lambda x}]_0^{+\infty} + \int_0^{+\infty} e^{-\lambda x} dx$$

$$\begin{aligned}
 &= \int_0^{+\infty} e^{-\lambda x} dx \\
 &= \left[-\frac{1}{\lambda} e^{-\lambda x} \right]_0^{+\infty} = \frac{1}{\lambda}
 \end{aligned}$$

et pour la variance on a :

$$V(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$$

Nous avons déjà calculé $\mathbb{E}(X)$. Pour calculer $\mathbb{E}(X^2)$, nous utilisons la définition de l'espérance :

$$\mathbb{E}(X^2) = \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx$$

En utilisant la formule d'intégration par parties :

$$u = x^2 \longrightarrow du = 2x$$

$$dv = \lambda e^{-\lambda x} \longrightarrow v = -e^{-\lambda x}$$

donc, nous obtenons :

$$\mathbb{E}(X^2) = [-x^2 e^{-\lambda x}]_0^{+\infty} + 2 \int_0^{+\infty} x e^{-\lambda x} dx = 2 \int_0^{+\infty} x e^{-\lambda x} dx$$

En utilisant une deuxième intégration par parties :

$$u = 2x \longrightarrow du = 2$$

$$dv = e^{-\lambda x} \longrightarrow v = -\frac{1}{\lambda} e^{-\lambda x}$$

donc

$$\begin{aligned}
 \mathbb{E}(X^2) &= \left[-\frac{2}{\lambda} x e^{-\lambda x} \right]_0^{+\infty} + \frac{2}{\lambda} \int_0^{+\infty} e^{-\lambda x} dx \\
 &= \left[-\frac{2}{\lambda^2} e^{-\lambda x} \right]_0^{+\infty} = \frac{2}{\lambda^2}
 \end{aligned}$$

d'où

$$V(X) = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

□

3- Loi Normale

Définition 2.5.7. Une variable aléatoire réelle X , prenant ses valeurs dans $\mathbb{R}$, suit une loi normale, de paramètres m et σ , si sa densité de probabilité est donnée par :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-m)^2}{2\sigma^2}}$$

La fonction f définit une densité. En effet :

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$

Cette loi est notée, en général $N(m; \sigma)$.

Sa fonction de répartition :

$$\mathbb{P}(X < a) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^a e^{-\frac{(x-m)^2}{2\sigma^2}} dx$$


Ses moments sont :

$$\mathbb{E}(X) = m, V(X) = \sigma^2$$

Cette intégrale n'ayant pas d'expression mathématique simple, des tables donnent les valeurs de la fonction de répartition.

Propriété 2. 1) Soient X_1 et X_2 sont deux variables aléatoires indépendantes suivant la loi normale $\mathcal{N}_1(m_1, \sigma_1^2)$ et $\mathcal{N}_2(m_2, \sigma_2^2)$ respectivement, alors $X_1 + X_2$ suit la loi normale $\mathcal{N}(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$
2) si $X \sim \mathcal{N}(m, \sigma^2)$, alors pour toute constante a et b , $aX+b$ suit la loi normale $\mathcal{N}(am + b, a^2\sigma^2)$

Table de Loi Normale
 $P(x < u)$



	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8254	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998

FRACTILES DE LA LOI NORMALE RÉDUITE

TABLE N° 2

Cette table donne les **valeurs absolues** des fractiles u_p de la loi $\mathcal{N}(0; 1)$: $\Phi(u_p) = \int_{-\infty}^{u_p} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = p$.

Pour $p < 0.5$: colonne de gauche et ligne supérieure et les fractiles u_p sont négatifs.

Pour $p \geq 0.5$: colonne de droite et ligne inférieure et les fractiles u_p sont positifs.

$\sqrt{p} < 0.5$	0.000	0.001	0.002	0.003	0.004	0.005	0.006	0.007	0.008	0.009	0.010	
0.00	∞	3.0902	2.8782	2.7478	2.6521	2.5758	2.5121	2.4573	2.4089	2.3656	2.3263	0.99
0.01	2.3263	2.2904	2.2571	2.2262	2.1973	2.1701	2.1444	2.1201	2.0969	2.0749	2.0537	0.98
0.02	2.0537	2.0335	2.0141	1.9954	1.9774	1.9600	1.9431	1.9268	1.9110	1.8957	1.8808	0.97
0.03	1.8808	1.8663	1.8522	1.8384	1.8250	1.8119	1.7991	1.7866	1.7744	1.7624	1.7507	0.96
0.04	1.7507	1.7392	1.7279	1.7169	1.7060	1.6954	1.6849	1.6747	1.6646	1.6546	1.6449	0.95
0.05	1.6449	1.6352	1.6258	1.6164	1.6072	1.5982	1.5893	1.5805	1.5718	1.5632	1.5548	0.94
0.06	1.5548	1.5464	1.5382	1.5301	1.5220	1.5141	1.5063	1.4985	1.4909	1.4833	1.4758	0.93
0.07	1.4758	1.4684	1.4611	1.4538	1.4466	1.4395	1.4325	1.4255	1.4187	1.4118	1.4051	0.92
0.08	1.4051	1.3984	1.3917	1.3852	1.3787	1.3722	1.3658	1.3595	1.3532	1.3469	1.3408	0.91
0.09	1.3408	1.3346	1.3285	1.3225	1.3165	1.3106	1.3047	1.2988	1.2930	1.2873	1.2816	0.90
0.10	1.2816	1.2759	1.2702	1.2646	1.2591	1.2536	1.2481	1.2426	1.2372	1.2319	1.2265	0.89
0.11	1.2265	1.2212	1.2160	1.2107	1.2055	1.2004	1.1952	1.1901	1.1850	1.1800	1.1750	0.88
0.12	1.1750	1.1700	1.1650	1.1601	1.1552	1.1503	1.1455	1.1407	1.1359	1.1311	1.1264	0.87
0.13	1.1264	1.1217	1.1170	1.1123	1.1077	1.1031	1.0985	1.0939	1.0893	1.0848	1.0803	0.86
0.14	1.0803	1.0758	1.0714	1.0669	1.0625	1.0581	1.0537	1.0494	1.0450	1.0407	1.0364	0.85
0.15	1.0364	1.0322	1.0279	1.0237	1.0194	1.0152	1.0110	1.0069	1.0027	0.9986	0.9945	0.84
0.16	0.9945	0.9904	0.9863	0.9822	0.9782	0.9741	0.9701	0.9661	0.9621	0.9581	0.9542	0.83
0.17	0.9542	0.9502	0.9463	0.9424	0.9385	0.9346	0.9307	0.9269	0.9230	0.9192	0.9154	0.82
0.18	0.9154	0.9116	0.9078	0.9040	0.9002	0.8965	0.8927	0.8890	0.8853	0.8816	0.8779	0.81
0.19	0.8779	0.8742	0.8705	0.8669	0.8632	0.8596	0.8560	0.8524	0.8488	0.8452	0.8416	0.80
0.20	0.8416	0.8381	0.8345	0.8310	0.8274	0.8239	0.8204	0.8169	0.8134	0.8099	0.8064	0.79
0.21	0.8064	0.8030	0.7995	0.7961	0.7926	0.7892	0.7858	0.7824	0.7790	0.7756	0.7722	0.78
0.22	0.7722	0.7688	0.7655	0.7621	0.7588	0.7554	0.7521	0.7488	0.7454	0.7421	0.7388	0.77
0.23	0.7388	0.7356	0.7323	0.7290	0.7257	0.7225	0.7192	0.7160	0.7128	0.7095	0.7063	0.76
0.24	0.7063	0.7031	0.6999	0.6967	0.6935	0.6903	0.6871	0.6840	0.6808	0.6776	0.6745	0.75
0.25	0.6745	0.6713	0.6682	0.6651	0.6620	0.6588	0.6557	0.6526	0.6495	0.6464	0.6433	0.74
0.26	0.6433	0.6403	0.6372	0.6341	0.6311	0.6280	0.6250	0.6219	0.6189	0.6158	0.6128	0.73
0.27	0.6128	0.6098	0.6068	0.6038	0.6008	0.5978	0.5948	0.5918	0.5888	0.5858	0.5828	0.72
0.28	0.5828	0.5799	0.5769	0.5740	0.5710	0.5681	0.5651	0.5622	0.5592	0.5563	0.5534	0.71
0.29	0.5534	0.5505	0.5476	0.5446	0.5417	0.5388	0.5359	0.5330	0.5302	0.5273	0.5244	0.70
0.30	0.5244	0.5215	0.5187	0.5158	0.5129	0.5101	0.5072	0.5044	0.5015	0.4987	0.4959	0.69
0.31	0.4959	0.4930	0.4902	0.4874	0.4845	0.4817	0.4789	0.4761	0.4733	0.4705	0.4677	0.68
0.32	0.4677	0.4649	0.4621	0.4593	0.4565	0.4538	0.4510	0.4482	0.4454	0.4427	0.4399	0.67
0.33	0.4399	0.4372	0.4344	0.4316	0.4289	0.4261	0.4234	0.4207	0.4179	0.4152	0.4125	0.66
0.34	0.4125	0.4097	0.4070	0.4043	0.4016	0.3989	0.3961	0.3934	0.3907	0.3880	0.3853	0.65
0.35	0.3853	0.3826	0.3799	0.3772	0.3745	0.3719	0.3692	0.3665	0.3638	0.3611	0.3585	0.64
0.36	0.3585	0.3558	0.3531	0.3505	0.3478	0.3451	0.3425	0.3398	0.3372	0.3345	0.3319	0.63
0.37	0.3319	0.3292	0.3266	0.3239	0.3213	0.3186	0.3160	0.3134	0.3107	0.3081	0.3055	0.62
0.38	0.3055	0.3029	0.3002	0.2976	0.2950	0.2924	0.2898	0.2871	0.2845	0.2819	0.2793	0.61
0.39	0.2793	0.2767	0.2741	0.2715	0.2689	0.2663	0.2637	0.2611	0.2585	0.2559	0.2533	0.60
0.40	0.2533	0.2508	0.2482	0.2456	0.2430	0.2404	0.2378	0.2353	0.2327	0.2301	0.2275	0.59
0.41	0.2275	0.2250	0.2224	0.2198	0.2173	0.2147	0.2121	0.2096	0.2070	0.2045	0.2019	0.58
0.42	0.2019	0.1993	0.1968	0.1942	0.1917	0.1891	0.1866	0.1840	0.1815	0.1789	0.1764	0.57
0.43	0.1764	0.1738	0.1713	0.1687	0.1662	0.1637	0.1611	0.1586	0.1560	0.1535	0.1510	0.56
0.44	0.1510	0.1484	0.1459	0.1434	0.1408	0.1383	0.1358	0.1332	0.1307	0.1282	0.1257	0.55
0.45	0.1257	0.1231	0.1206	0.1181	0.1156	0.1130	0.1105	0.1080	0.1055	0.1030	0.1004	0.54
0.46	0.1004	0.0979	0.0954	0.0929	0.0904	0.0878	0.0853	0.0828	0.0803	0.0778	0.0753	0.53
0.47	0.0753	0.0728	0.0702	0.0677	0.0652	0.0627	0.0602	0.0577	0.0552	0.0527	0.0502	0.52
0.48	0.0502	0.0476	0.0451	0.0426	0.0401	0.0376	0.0351	0.0326	0.0301	0.0276	0.0251	0.51
0.49	0.0251	0.0226	0.0201	0.0175	0.0150	0.0125	0.0100	0.0075	0.0050	0.0025	0.0000	0.50
	0.010	0.009	0.008	0.007	0.006	0.005	0.004	0.003	0.002	0.001	0.000	$p \geq 0.5$

4- Loi gamma :

Définition 2.5.8. Une variable aléatoire réelle positive X suit une loi gamma $\Gamma(a, \theta)$ où $a, \theta > 0$, si sa densité de probabilité est donnée par :

$$f(x) = \frac{\theta^a}{\Gamma(a)} x^{a-1} e^{-\theta x} 1_{x>0}$$

On note Γ la fonction gamma :

$$\forall a > 0, \Gamma(a) = \int_0^{+\infty} x^{a-1} e^{-x} dx$$

Ses moments sont :

$$\begin{aligned} \mathbb{E}(X) &= \frac{a}{\theta} \\ V(X) &= \frac{a}{\theta^2} \end{aligned}$$

Démonstration. L'espérance $\mathbb{E}(X)$ d'une variable aléatoire X suivant une loi gamma est définie comme suit :

$$\begin{aligned} \mathbb{E}(X) &= \int_0^{+\infty} x \left(\frac{\theta^a}{\Gamma(a)} x^{a-1} e^{-\theta x} \right) dx \\ &= \frac{\theta^a}{\Gamma(a)} \int_0^{+\infty} x^a e^{-\theta x} dx \end{aligned}$$

or
 $\int_0^{+\infty} x^a e^{-\theta x} dx = \frac{\Gamma(a+1)}{\theta^{a+1}}$
 donc

$$\mathbb{E}(X) = \frac{\theta^a}{\Gamma(a)} \frac{\Gamma(a+1)}{\theta^{a+1}} = \frac{a}{\theta}$$

et pour la variance on a :

$$V(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$$

Nous avons déjà calculé $\mathbb{E}(X)$. Pour calculer $\mathbb{E}(X^2)$, nous utilisons la définition de l'espérance :

$$\begin{aligned} \mathbb{E}(X^2) &= \int_0^{+\infty} x^2 \left(\frac{\theta^a}{\Gamma(a)} x^{a-1} e^{-\theta x} \right) dx \\ &= \frac{\theta^a}{\Gamma(a)} \int_0^{+\infty} x^{a+1} e^{-\theta x} dx \end{aligned}$$

or
 $\int_0^{+\infty} x^{a+1} e^{-\theta x} dx = \frac{\Gamma(a+2)}{\theta^{a+2}}$ donc

$$\mathbb{E}(X) = \frac{\theta^a}{\Gamma(a)} \frac{\Gamma(a+2)}{\theta^{a+2}} = \frac{a(a+1)}{\theta^2}$$

d'où

$$V(X) = \frac{a(a+1)}{\theta^2} - \frac{a^2}{\theta^2} = \frac{a}{\theta^2}$$

□

Propriété 3. on a

$\forall a > 0, \Gamma(a+1) = a\Gamma(a)$ et

$\forall n \in \mathbb{N}^*, \Gamma(n) = (n-1)!$

Démonstration. Pour montrer que $\Gamma(a+1) = a\Gamma(a)$, considérons l'intégrale qui définit $\Gamma(a+1)$:

$$\Gamma(a+1) = \int_0^{+\infty} x^a e^{-x} dx$$

En effectuant une intégration par parties, où nous posons :

$$u = x^a \text{ et donc } du = ax^{a-1} dx$$

$$dv = e^{-x} dx \text{ et donc } v = -e^{-x}$$

nous obtenons :

$$\begin{aligned} \Gamma(a+1) &= \int_0^{+\infty} x^a e^{-x} dx \\ &= [-x^a e^{-x}]_0^{+\infty} + \int_0^{+\infty} ax^{a-1} e^{-x} dx \\ &= a \int_0^{+\infty} x^{a-1} e^{-x} dx \\ &= a\Gamma(a) \end{aligned}$$

□

2.6 Loi gaussienne, loi du chi-deux, loi de Student

2.6.1 Loi gaussienne :

Définition 2.6.1. on dit que la variable aléatoire réelle X suit la loi gaussienne d'espérance $m \in \mathbb{R}$ et de variance nulle si $\mathbb{P}(X = m) = 1$. On note alors $X \sim \mathcal{N}(m, 0)$

Définition 2.6.2 (variance empirique).

La variance empirique $\mathcal{S}^2$ d'un échantillon de taille n est définie par :

$$\mathcal{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

expression qui peut s'écrire :

$$\mathcal{S}^2 = \frac{1}{n} \left(\sum_{i=1}^n (X_i - m)^2 \right) - (m - \bar{X})^2$$

Démonstration. On a :

$$\begin{aligned} \mathcal{S}^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m + m - \bar{X})^2 \\ &= \frac{1}{n} \left(\sum_{i=1}^n ((X_i - m)^2 + 2(X_i - m)(m - \bar{X}) + (m - \bar{X})^2) \right) \\ &= \frac{1}{n} \left(\sum_{i=1}^n (X_i - m)^2 \right) + \frac{2}{n} (m - \bar{X}) \left(\sum_{i=1}^n (X_i - m) \right) + (m - \bar{X})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 - (m - \bar{X})^2 \end{aligned}$$

□

2.6.2 Loi du chi-deux :

Définition 2.6.3. Si X_i sont n variables aléatoires indépendantes de loi normale avec moyenne m_i et écart-type σ_i , alors la variable

$$Y = \sqrt{\sum_{i=1}^n \left(\frac{X_i - m_i}{\sigma_i} \right)^2}$$

est de loi du χ^2 .

La loi χ^2 de n degrés de liberté est la loi $\Gamma(\frac{n}{2}, \frac{1}{2})$ de densité

$$f(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1} & \text{si } x \geq 0 \\ 0 & \text{sinon} \end{cases}$$

L'espérance et la variance d'une variable aléatoire suivant une loi χ^2 avec n degrés de liberté sont égales :

$$\mathbb{E}(X) = n$$

$$V(X) = 2n$$

Démonstration. pour $f : \mathbb{R} \rightarrow \mathbb{R}$ bornée et $X \sim \mathcal{N}(0, 1)$

$$\begin{aligned} \mathbb{E}(f(X^2)) &= \int_{\mathbb{R}} f(x^2) \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} dx \\ &= 2 \int_0^{+\infty} f(x^2) \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} dx \end{aligned}$$

en posant $y = x^2 \longrightarrow dx = \frac{1}{2} dy$

$$= \int_0^{+\infty} f(y) \frac{e^{-\frac{y}{2}}}{\sqrt{2\pi y}} dy$$

ainsi $\chi^2(1) = \Gamma(\frac{1}{2}, \frac{1}{2})$ et on conclut par récurrence que $\chi^2(n) = \Gamma(\frac{n}{2}, \frac{1}{2})$. □

2.6.3 Loi de Student :

Définition 2.6.4. Soit Z une variable aléatoire de loi normale centrée et réduite et soit U une variable indépendante de Z et distribuée suivant la loi du χ^2 à n degrés de liberté. Par définition, la variable

$$\mathcal{T} = \frac{Z}{\sqrt{U/n}}$$

suit une loi de Student à n degrés de liberté.

La densité de $\mathcal{T}$, notée $f_{\mathcal{T}}$, est donnée par :

$\forall n \in \mathbb{N}^*$


$$f_{\mathcal{T}}(x) = \frac{1}{\sqrt{\pi n}} \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$$

Voici les tables respectives reliées de la loi χ^2 et $\mathcal{T}$

Table de distribution de χ^2 (loi de K. Pearson)

La table donne la probabilité α , en fonction du nombre de degrés de liberté ν , pour que χ^2 égale ou dépasse une valeur donnée χ^2_α .

$$\alpha = P(\chi^2 \geq \chi^2_\alpha)$$




ν	$\alpha = 0,990$	$\alpha = 0,975$	$\alpha = 0,950$	$\alpha = 0,900$	$\alpha = 0,100$	$\alpha = 0,050$	$\alpha = 0,025$	$\alpha = 0,010$	$\alpha = 0,001$
1	0,0002	0,0010	0,0039	0,0158	2,71	3,84	5,02	6,63	10,83
2	0,02	0,05	0,10	0,21	4,61	5,99	7,38	9,21	13,82
3	0,12	0,22	0,35	0,58	6,25	7,81	9,35	11,34	16,27
4	0,30	0,48	0,71	1,06	7,78	9,49	11,14	13,28	18,47
5	0,55	0,83	1,15	1,61	9,24	11,07	12,83	15,09	20,52
6	0,87	1,24	1,64	2,20	10,64	12,59	14,45	16,81	22,46
7	1,24	1,69	2,17	2,83	12,02	14,07	16,01	18,47	24,32
8	1,65	2,18	2,73	3,49	13,36	15,51	17,53	20,09	26,13
9	2,09	2,70	3,33	4,17	14,68	16,92	19,02	21,67	27,88
10	2,56	3,25	3,94	4,87	15,99	18,31	20,48	23,21	29,59
11	3,05	3,82	4,57	5,58	17,27	19,67	21,92	24,72	31,26
12	3,57	4,40	5,23	6,30	18,55	21,03	23,34	26,22	32,91
13	4,11	5,01	5,89	7,04	19,81	22,36	24,74	27,69	34,53
14	4,66	5,63	6,57	7,79	21,06	23,68	26,12	29,14	36,12
15	5,23	6,26	7,26	8,55	22,31	25,00	27,49	30,58	37,70
16	5,81	6,91	7,96	9,31	23,54	26,30	28,84	32,00	39,25
17	6,41	7,56	8,67	10,08	24,77	27,59	30,19	33,41	40,79
18	7,01	8,23	9,39	10,86	25,99	28,87	31,53	34,80	42,31
19	7,63	8,91	10,12	11,65	27,20	30,14	32,85	36,19	43,82
20	8,26	9,59	10,85	12,44	28,41	31,41	34,17	37,57	45,32
21	8,90	10,28	11,59	13,24	29,61	32,67	35,48	38,93	46,80
22	9,54	10,98	12,34	14,04	30,81	33,92	36,78	40,29	48,27
23	10,20	11,69	13,09	14,85	32,01	35,17	38,08	41,64	49,73
24	10,86	12,40	13,85	15,66	33,20	36,41	39,37	42,98	51,18
25	11,52	13,12	14,61	16,47	34,38	37,65	40,65	44,31	52,62
26	12,20	13,84	15,38	17,29	35,56	38,88	41,92	45,64	54,05
27	12,88	14,57	16,15	18,11	36,74	40,11	43,19	46,96	55,48
28	13,57	15,31	16,93	18,94	37,92	41,34	44,46	48,28	56,89
29	14,26	16,05	17,71	19,77	39,09	42,56	45,72	49,59	58,30
30	14,95	16,79	18,49	20,60	40,26	43,77	46,98	50,89	59,70

Quand ν est supérieur à 30, on utilise la table de la loi normale (table de l'écart réduit) avec :

$$t = \sqrt{2\chi^2} - \sqrt{2\nu - 1}$$

Table de la loi de Student

Valeurs de T ayant la probabilité P d'être dépassées en valeur absolue


ν	$P=0,90$	0,80	0,70	0,60	0,50	0,40	0,30	0,20	0,10	0,05	0,02	0,01
1	0,158	0,325	0,510	0,727	1,000	1,376	1,963	3,078	6,314	12,706	31,821	63,657
2	0,142	0,289	0,445	0,617	0,816	1,061	1,386	1,886	2,920	4,303	6,965	9,925
3	0,137	0,277	0,424	0,584	0,765	0,978	1,250	1,638	2,353	3,182	4,541	5,841
4	0,134	0,271	0,414	0,569	0,741	0,941	1,190	1,533	2,132	2,776	3,747	4,604
5	0,132	0,267	0,408	0,559	0,727	0,920	1,156	1,476	2,015	2,571	3,365	4,032
6	0,131	0,265	0,404	0,553	0,718	0,906	1,134	1,440	1,943	2,447	3,143	3,707
7	0,130	0,263	0,402	0,549	0,711	0,896	1,119	1,415	1,895	2,365	2,998	3,499
8	0,130	0,262	0,399	0,546	0,706	0,889	1,108	1,397	1,860	2,306	2,896	3,355
9	0,129	0,261	0,398	0,543	0,703	0,883	1,100	1,383	1,833	2,262	2,821	3,250
10	0,129	0,260	0,397	0,542	0,700	0,879	1,093	1,372	1,812	2,228	2,764	3,169
11	0,129	0,260	0,396	0,540	0,697	0,876	1,088	1,363	1,796	2,201	2,718	3,106
12	0,128	0,260	0,395	0,539	0,695	0,873	1,083	1,356	1,782	2,179	2,681	3,055
13	0,128	0,259	0,394	0,538	0,694	0,870	1,079	1,350	1,771	2,160	2,650	3,012
14	0,128	0,258	0,393	0,537	0,692	0,868	1,076	1,345	1,761	2,145	2,624	2,977
15	0,128	0,258	0,393	0,536	0,691	0,866	1,074	1,341	1,753	2,131	2,602	2,947
16	0,128	0,258	0,392	0,535	0,690	0,865	1,071	1,337	1,746	2,120	2,583	2,921
17	0,128	0,257	0,392	0,534	0,689	0,863	1,069	1,333	1,740	2,110	2,567	2,898
18	0,127	0,257	0,392	0,534	0,688	0,862	1,067	1,330	1,734	2,101	2,552	2,878
19	0,127	0,257	0,391	0,533	0,688	0,861	1,066	1,328	1,729	2,093	2,539	2,861
20	0,127	0,257	0,391	0,533	0,687	0,860	1,064	1,325	1,725	2,086	2,528	2,845
21	0,127	0,257	0,391	0,532	0,686	0,859	1,063	1,323	1,721	2,080	2,518	2,831
22	0,127	0,256	0,390	0,532	0,686	0,858	1,061	1,321	1,717	2,074	2,508	2,819
23	0,127	0,256	0,390	0,532	0,685	0,858	1,060	1,319	1,714	2,069	2,500	2,807
24	0,127	0,256	0,390	0,531	0,685	0,857	1,059	1,318	1,711	2,064	2,492	2,797
25	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,316	1,708	2,060	2,485	2,787
26	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,315	1,706	2,056	2,479	2,779
27	0,127	0,256	0,389	0,531	0,684	0,855	1,057	1,314	1,703	2,052	2,473	2,771
28	0,127	0,256	0,389	0,530	0,683	0,855	1,056	1,313	1,701	2,048	2,467	2,763
29	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,311	1,699	2,045	2,462	2,756
30	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,310	1,697	2,042	2,457	2,750
∞	0,126	0,253	0,385	0,524	0,674	0,842	1,036	1,282	1,645	1,96	2,326	2,576

Nota. ν est le nombre de degrés de liberté.

Le quantile d'ordre $1 - \frac{\alpha}{2}$ se lit dans la colonne $P = \alpha$.

Le quantile d'ordre $1 - \alpha$ se lit dans la colonne $P = 2\alpha$.

Chapitre 3

Convergence des variables aléatoires

3.1 Inégalités probabilistes

3.1.1 Inégalité de Markov

Soit X une variable aléatoire réelle positive admettant une espérance sur $(\Omega, \mathcal{A}, \mathcal{P})$.
Soit $a > 0$ alors :

$$\mathbb{P}(x \geq a) \leq \frac{\mathbb{E}(X)}{a}$$

Démonstration.

$$\begin{aligned} \mathbb{E}(X) &= \sum_{x \in X(\Omega)} x \mathbb{P}(X = x) = \sum_{x \geq a} x \mathbb{P}(X = x) + \sum_{x < a} x \mathbb{P}(X = x) \\ &\geq \sum_{x \geq a} x \mathbb{P}(X = x) \\ &\geq (a \sum_{x \geq a} \mathbb{P}(X = x)) = a \mathbb{P}(X \geq a) \end{aligned}$$

donc $\mathbb{P}(x \geq a) \leq \frac{\mathbb{E}(X)}{a}$

□

3.1.2 Inégalité de Bienaymé-Tchebychev

Soit une variable aléatoire réelle X de carré intégrable, définie sur un espace de probabilité sur $(\Omega, \mathcal{A}, \mathcal{P})$ et pour tout $a > 0$ on a :

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq \epsilon) \leq \frac{V(X)}{\epsilon^2}$$

Démonstration. Soit $\epsilon > 0$,

$$|X - \mathbb{E}(X)| \geq \epsilon \iff (|X - \mathbb{E}(X)|)^2 \geq \epsilon^2$$

donc

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq \epsilon) = \mathbb{P}(|X - \mathbb{E}(X)|^2 \geq \epsilon^2)$$

En appliquant l'inégalité de Markov, nous obtenons

$$\mathbb{P}((X - \mathbb{E}(X))^2 \geq \epsilon^2) \leq \frac{\mathbb{E}((X - \mathbb{E}(X))^2)}{\epsilon^2} = \frac{V(X)}{\epsilon^2}$$

D'où le résultat.

□

3.2 Les différentes modes de convergence

Définition 3.2.1. Soit $(X_n)_n$ et X définies sur $(\Omega, \mathcal{A}, \mathcal{P})$ à valeurs dans $\mathbb{R}^d$. On dit X_n converge vers la variable aléatoire X

- presque sûrement si

$$\mathbb{P}(\lim_{n \rightarrow \infty} X_n = X) = 1 \iff \mathbb{P}(\lim_{n \rightarrow \infty} X_n \neq X) = 0$$

- en probabilité si, pour tout $\epsilon > 0$,

$$\mathbb{P}(|X_n - X| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$$

- dans L^p si

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^p) = 0$$

Proposition 3.2.1.

1) on a

$$\begin{aligned} \left(\lim_{n \rightarrow \infty} X_n = X \right) &= \bigcap_{\epsilon \in]0,1[\cap \mathbb{Q}} \bigcup_n \bigcap_{n \geq k} (|X_n - X| < \epsilon) \\ \left(\lim_{n \rightarrow \infty} X_n \neq X \right) &= \bigcup_{\epsilon \in]0,1[\cap \mathbb{Q}} \bigcap_n \bigcup_{n \geq k} (|X_n - X| > \epsilon) \end{aligned}$$

2) si X_n converge vers X en probabilité $(X_n \xrightarrow[n \rightarrow \infty]{p} X)$ et Y_n converge vers Y en probabilité $(Y_n \xrightarrow[n \rightarrow \infty]{p} Y)$ alors

$$\alpha X_n + \beta Y_n \xrightarrow[n \rightarrow \infty]{p} \alpha X + \beta Y$$

3) $\forall 1 \leq p \leq q$ alors :

$$cv(L^q) \implies cv(L^p) \implies cv(L^1)$$

4) si

$$\begin{aligned} X_n &\xrightarrow[n \rightarrow \infty]{L^p} X \\ Y_n &\xrightarrow[n \rightarrow \infty]{L^p} Y \end{aligned}$$

alors

$$\begin{aligned} i) \alpha X_n + \beta Y_n &\xrightarrow[n \rightarrow \infty]{L^p} \alpha X + \beta Y \\ ii) X_n Y_n &\xrightarrow[n \rightarrow \infty]{L^p} XY \end{aligned}$$

Démonstration. 4) Pour montrer que $\alpha X_n + \beta Y_n \xrightarrow[n \rightarrow \infty]{L^p} \alpha X + \beta Y$ il suffit de montrer que :

$$\|\alpha X_n + \beta Y_n - (\alpha X + \beta Y)\|_p \xrightarrow[n \rightarrow \infty]{} 0$$

Utilisons l'inégalité triangulaire :

$$\|\alpha X_n + \beta Y_n - (\alpha X + \beta Y)\|_p \leq |\alpha| \|X_n - X\|_p + |\beta| \|Y_n - Y\|_p$$

puisque $\|X_n - X\|_p \rightarrow 0$ et $\|Y_n - Y\|_p \rightarrow 0$, on a :

$$\alpha X_n + \beta Y_n \xrightarrow[n \rightarrow \infty]{L^p} \alpha X + \beta Y$$

Pour montrer que $X_n Y_n \xrightarrow[n \rightarrow \infty]{L^p} XY$, il suffit de montrer que $\|X_n Y_n - XY\|_p \xrightarrow[n \rightarrow \infty]{} 0$
on a

$\|X_n Y_n - XY\|_p = \|(X_n - X)Y_n + X(Y_n - Y)\|_p \leq \|(X_n - X)Y_n\|_p + \|X(Y_n - Y)\|_p$
 Utilisons l'inégalité de Hölder pour les normes L^p :

$$\|(X_n - X)Y_n\|_p \leq \|X_n - X\|_p \|Y_n\|_\infty$$

Si nous supposons que Y_n est borné dans L^p , donc $\exists M > 0$ tq $\|Y_n\|_\infty \leq M$ pour tout n et alors

$$\|(X_n - X)Y_n\|_p \leq M \|(X_n - X)Y_n\|_p$$

et de même

$$\|X(Y_n - Y)\|_p \leq \|X\|_\infty \|Y_n - Y\|_p$$

supposons que X est borné dans L^p , donc $\exists N > 0$ tq $\|X\|_\infty \leq N$, alors

$$\|X(Y_n - Y)\|_p \leq N \|Y_n - Y\|_p$$

puisque $\|X_n - X\|_p \rightarrow 0$ et $\|Y_n - Y\|_p \rightarrow 0$, alors :

$$\|X_n Y_n - XY\|_p \leq \|(X_n - X)Y_n\|_p + \|X(Y_n - Y)\|_p \xrightarrow[n \rightarrow \infty]{} 0$$

□

Proposition 3.2.2. *La convergence presque sûre entraîne la convergence en probabilité mais la réciproque est fausse.*

Exemple 3.2.1. Soit $p > 0$. On considère $(X_n)_n$ une suite de variables aléatoires indépendantes telle que

$$\mathbb{P}(X_n = n^{\frac{1}{p}}) = \frac{1}{n}$$

et

$$\mathbb{P}(X_n = 0) = 1 - \frac{1}{n}$$

Montrons qu'elle ne converge pas non plus presque sûrement. Si c'était le cas sa limite presque sûre serait nécessairement sa limite en probabilité, à savoir 0. Or, comme $\sum_n \mathbb{P}(X_n = n^{\frac{1}{p}}) = \infty$ et comme les variables aléatoires X_n sont indépendantes, on a par le lemme de Borel-Contelli

$$\mathbb{P}(\limsup_n (X_n = n^{\frac{1}{p}})) = 1$$

Alors, X_n ne converge pas presque sûrement vers 0.

Théorème 3.2.1 (lemme de Borel-Contelli).

Soit $(\Omega, \mathcal{A}, \mathcal{P})$ un espace probabilisé et soit $(X_n)_n$ une famille des événements dans $\mathcal{A}$.

i) Si $\sum_{k=1}^n \mathbb{P}(X_k) < \infty$ alors $\mathbb{P}(\limsup_n X_n) = 0$

ii) Si les $(X_n)_n$ sont indépendants et $\sum_{k=1}^n \mathbb{P}(X_k) = \infty$ alors $\mathbb{P}(\limsup_n X_n) = 1$

Démonstration. i) D'après la propriété de continuité ($A = \lim_{n \rightarrow \infty} A_n$ alors $\mathbb{P}(A) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n)$) on a :

$$\mathbb{P}(\limsup A_n) = \mathbb{P}(\lim_{n \rightarrow \infty} \cup_{k=1}^n A_k) = \lim_{n \rightarrow \infty} \mathbb{P}(\cup_{k=1}^n A_k)$$

et

$$\mathbb{P}(\cup_{k=1}^n A_k) \leq \sum_{k=1}^n \mathbb{P}(A_k)$$

Le deuxième membre de l'inégalité précédente tend vers 0 (le reste d'une série convergente). $\mathbb{P}(\cup_{k=1}^n A_k)$ est donc le terme général d'une suite encadrée par 0 et d'une suite décroissante de limite 0, et donc $\lim_{n \rightarrow \infty} \mathbb{P}(\cup_{k=1}^n A_k) = 0$

ii) $\mathbb{P}(\cup_{k=1}^n A_k) = 1 - \mathbb{P}(\cap_{k=1}^n \overline{A_k}) = 1 - \prod_{k=1}^n \mathbb{P}(\overline{A_k})$ grace à l'indépendance des A_k .
par continuité de l'application probabilité :

$$\mathbb{P}(\cup_{k=1}^n A_k) = 1 - \mathbb{P}(\cap_{k=1}^n \overline{A_k}) = 1 - \prod_{k=1}^n \mathbb{P}(\overline{A_k}) = 1 - \prod_{k=1}^n (1 - \mathbb{P}(A_k))$$

et puisque $1 - x \leq e^{-x}$, $\forall x \geq 0$

$$\prod_{k=1}^n (1 - \mathbb{P}(A_k)) \leq e^{-\sum_{k=1}^n \mathbb{P}(A_k)}$$

et grace à l'hypothèse

$$\lim_{n \rightarrow +\infty} \sum_{k=1}^n \mathbb{P}(A_k) = +\infty$$

donc

$$\mathbb{P}(\cup_{k=1}^n A_k) = 1 - \prod_{k=1}^n (1 - \mathbb{P}(A_k)) = 1$$

et alors

$$\mathbb{P}(\limsup A_n) = \lim_{n \rightarrow +\infty} \mathbb{P}(\cup_{k=1}^n A_k) = 1$$

□

Proposition 3.2.3. *La convergence L^p entraîne la convergence en L^1 .*

Démonstration. Si (X_n) converge en L^p vers X alors :

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^p) = 0$$

et Si (X_n) converge en L^1 vers X alors :

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|) = 0$$

en appliquant l'inégalité de Hölder,

Soit $p > 1$ et $q > 1$, tq $\frac{1}{p} + \frac{1}{q} = 1$

$$\begin{aligned} \mathbb{E}(|X_n - X| \times 1) &\leq \mathbb{E}(|X_n - X|^p)^{\frac{1}{p}} \times \mathbb{E}(1^q)^{\frac{1}{q}} \\ &\leq \mathbb{E}(|X_n - X|^p)^{\frac{1}{p}} \end{aligned}$$

Donc

$$\mathbb{E}(|X_n - X|) \leq \mathbb{E}(|X_n - X|^p)^{\frac{1}{p}}$$

D'où

la convergence $L^p \implies$ la convergence L^1

□

Lemme 1 (Inégalité de Hölder).

Soit X et Y deux variables aléatoires, et $p, q > 1$ tq $\frac{1}{p} + \frac{1}{q} = 1$ alors :

$$\mathbb{E}(|XY|) \leq (\mathbb{E}(|X|^p))^{\frac{1}{p}} (\mathbb{E}(|Y|^q))^{\frac{1}{q}}$$

Proposition 3.2.4. La convergence L^p entraîne la convergence en probabilité.

Démonstration. Si (X_n) converge en L^p vers X alors :

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^p) = 0$$

et si (X_n) converge en probabilité vers X alors :

$$\mathbb{P}(\|X_n - X\| > \epsilon) \xrightarrow[n \rightarrow \infty]{} 0$$

en appliquant l'inégalité de Markov :

$$\begin{aligned} \mathbb{P}(\|X_n - X\| \geq \epsilon) &\leq \frac{\mathbb{E}(|X_n - X|^p)}{\epsilon^p} \\ \implies \lim_{n \rightarrow \infty} \mathbb{P}(\|X_n - X\| \geq \epsilon) &\leq \lim_{n \rightarrow \infty} \frac{\mathbb{E}(|X_n - X|^p)}{\epsilon^p} = 0 \end{aligned}$$

Donc $cv(L^p) \implies cv(P)$ □

Resumé :

Les relations entre les types de convergences, tels que la convergence presque sûre, la convergence en probabilité et la convergence L^p , offrent un aperçu essentiel de la façon dont les séquences de variables aléatoires convergent vers une limite.

D'après les trois dernières propositions, on conclut que la convergence en L^p implique la convergence en L^1 , ce qui implique la convergence en probabilité. De plus, la convergence presque sûre implique également la convergence en probabilité.

3.3 Fonction caractéristique

Définition 3.3.1. On appelle fonction caractéristique de la variable aléatoire X de loi P_X , la fonction $\phi_X(u)$ définie par :

$$\phi_X(u) = \mathbb{E}[e^{iuX}] = \int_{\omega} e^{iuX(\omega)} dP = \int_{\mathbb{R}} e^{iuX} dP_X$$

Dans le cas particulier où X est une variable aléatoire réelle discrète prenant les valeurs x_k avec les probabilités p_k :

$$\phi_X(u) = \mathbb{E}[e^{iuX}] = \sum_{k=1}^n e^{iux_k} p_k$$

et lorsque X est une variable aléatoire continue de densité de probabilité $f_X(x)$:

$$\phi_X(u) = \mathbb{E}[e^{iuX}] = \int_{-\infty}^{+\infty} e^{iux} f_X(x) dx$$

Propriété 4. 1) pour tout $a, b \in \mathbb{R}$

$$\phi_{aX+b}(u) = \mathbb{E}[e^{iu(aX+b)}] = \mathbb{E}(e^{iuaX} e^{iub}) = e^{iub} \mathbb{E}(e^{iuaX})$$

$$\phi_{aX+b}(u) = e^{iub} \phi_X(au)$$

2) $X_1, \dots, X_n$ variables aléatoires indépendantes $\iff \phi_X(u) = \prod_{k=1}^n \phi_{X_k}(u_k)$

3) si X une variable aléatoire telle que $\mathbb{E}(X^n)$ existe, alors $\phi_X(u)$ est n fois dérivable, de dérivée $n^{\text{ème}}$ continue et :

$$\phi_X(u) = \sum_{k=1}^n \frac{(iu)^k}{k!} m_k + o(u^n)$$

en particulier, si X est de carré intégrable, on a :

$$\phi_X(u) = 1 + iu\mathbb{E}(X) - \frac{1}{2}u^2\mathbb{E}(X^2) + o(u^2)$$

et puisque $\mathbb{E}(X^2) = V(X) + (\mathbb{E}(X))^2$ alors,

$$\phi_X(u) = 1 + ium_x - \frac{1}{2}u^2[\sigma_x^2 + m_x^2] + o(u^2)$$

4) On s'intéresse parfois à une fonction caractéristique appelée seconde fonction caractéristique. Cette fonction $\Psi_X(u) = \text{Log}[\phi_X(u)]$

3.4 Convergence en loi

Définition 3.4.1. Soit $(X_n)_n$ et X définies sur $(\Omega, \mathcal{A}, \mathcal{P})$ à valeurs dans $\mathbb{R}^d$. On dit que $(X_n)_n$ converge en loi vers X si pour tout h continue bornée, on a

$$\mathbb{E}(h(X_n)) \xrightarrow{n \rightarrow \infty} \mathbb{E}(h(X))$$

on note

$$X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$$

Proposition 3.4.1. 1) si $(X_n)_n$ et X sont discrètes alors $(X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X)$ ssi, pour tout a ,

$$\mathbb{P}(X_n = a) \xrightarrow{n \rightarrow \infty} \mathbb{P}(X = a)$$

2) Si la suite $(X_n)_n$ converge en loi vers la variable aléatoire X , alors pour tout f continue et bornée,

$$\mathbb{E}(f(X_n)) \xrightarrow{n \rightarrow \infty} \mathbb{E}(f(X))$$

Démonstration. 1) ($\implies$) Supposons que $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$

Dans le cas des variables discrètes, nous considérons les fonctions indicatrices $f_a(x) = 1_{\{x=a\}}$, pour tout $a \in \mathbb{R}$, on a

$$\mathbb{E}(f_a(X_n)) = \mathbb{P}(X_n = a) \text{ et } \mathbb{E}(f_a(X)) = \mathbb{P}(X = a)$$

Par conséquent, la convergence en loi implique que :

$$\mathbb{P}(X_n = a) \xrightarrow{n \rightarrow \infty} \mathbb{P}(X = a)$$

($\Leftarrow$) Supposons que, pour tout $a \in \mathbb{R}$, $\mathbb{P}(X_n = a) \xrightarrow{n \rightarrow \infty} \mathbb{P}(X = a)$

Pour montrer que $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$, il suffit de montrer que, pour toute fonction f continue bornée, on a :

$$\mathbb{E}(f(X_n)) \xrightarrow{n \rightarrow \infty} \mathbb{E}(f(X))$$

évident

2) La convergence en loi de X_n vers X signifie que pour toute fonction f continue bornée, on a :

$$\int_{\mathbb{R}} f(x) dF_{X_n}(x) \xrightarrow{n \rightarrow \infty} \int_{\mathbb{R}} f(x) dF_X(x)$$

où F_{X_n} et F_X sont les fonctions de répartition de X_n et X , respectivement.
donc

$$\mathbb{E}(f(X_n)) = \int_{\mathbb{R}} f(x) dF_{X_n}(x) \xrightarrow{n \rightarrow \infty} \int_{\mathbb{R}} f(x) dF_X(x) = \mathbb{E}(f(X))$$

□

Théorème 3.4.1. *La suite $(X_n)_n$ de variables aléatoires à valeurs dans $\mathbb{R}^d$ converge en loi vers la variable aléatoire X à valeurs $\mathbb{R}^d$ si et seulement si la fonction caractéristique de $(X_n)_n$ converge ponctuellement vers la fonction caractéristique de X .*

$$X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X \iff \phi_{X_n}(u) \rightarrow \phi_X(u), \forall u \in \mathbb{R}^d$$

Proposition 3.4.2. *La convergence en probabilité entraîne la convergence en loi.*

Démonstration. pour tout $\epsilon > 0$

$$\mathbb{P}(\|X_n - X\| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$$

Soit h continue et bornée

$$|\mathbb{E}(h(X_n)) - \mathbb{E}(h(X))| \leq \mathbb{E}(|h(X_n) - h(X)|)$$

$$\leq \mathbb{E}(\|h(X_n) - h(X)\| (1_{(\|h(X_n) - h(X)\| \geq \epsilon)} + 1_{(\|h(X_n) - h(X)\| < \epsilon)}))$$

on pose $|\mathbb{E}(h(X_n)) - \mathbb{E}(h(X))| = 2M$

donc

$$|\mathbb{E}(h(X_n)) - \mathbb{E}(h(X))| \leq 2M\mathbb{P}(\|X_n - X\| \geq \epsilon) + \mathbb{E}(\|h(X_n) - h(X)\| (1_{(\|h(X_n) - h(X)\| < \epsilon)}))$$

or h est continue, càd pour tout $\nu > 0, \exists \epsilon > 0$ tq,

$$\|X_n - X\| < \epsilon \implies \|h(X_n) - h(X)\| < \nu$$

d'où

$$\begin{aligned} |\mathbb{E}(h(X_n)) - \mathbb{E}(h(X))| &\leq 2M\mathbb{P}(\|X_n - X\| \geq \epsilon) + \nu \\ &\leq 2\nu \end{aligned}$$

d'où

$$\mathbb{P}(\|X_n - X\| \geq \epsilon) \leq \frac{\nu}{2M}$$

alors $\text{cv}(P) \implies \text{cv}(\mathcal{L})$

□

3.5 Lois des grands nombres

Soit $(X_n)_n$ une suite de variables aléatoires réelles indépendantes et de même loi de probabilité quelconque, Les lois des grands nombres portent sur le comportement de la moyenne empirique

$$M_n = \frac{1}{n} \sum_{k=1}^n X_k$$

Il existe plusieurs formulations des lois faible et forte des grands nombres qui diffèrent selon les hypothèses faites sur la suite X_n .

3.5.1 Loi faible des grands nombres

Si ces variables aléatoires X_n appartiennent à L^1 et ont pour espérance mathématique m , la variable aléatoire M_n converge en probabilité vers la variable aléatoire certaine $\mathbb{E}(X_n) = m$

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{P} \mathbb{E}(X_n)$$

3.5.2 Loi forte des grands nombres

Si ces variables aléatoires X_n appartiennent à L^1 et ont pour espérance mathématique m , la variable aléatoire M_n converge presque sûrement vers la variable aléatoire certaine $\mathbb{E}(X_n) = m$

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{P.S} \mathbb{E}(X_n)$$

3.5.3 Théoreme limite centrale

Si $(X_n)_{n \in \mathbb{N}}$ désigne une suite de variables aléatoires indépendantes appartenant à L^2 , de même loi de probabilité, d'espérance mathématique m et de variance σ^2 , la suite de variables aléatoires constituée par la somme $S_n = \sum_{k=1}^n X_k$ normalisée converge en loi vers une variable aléatoire u de loi de probabilité $\mathcal{N}(0, 1)$.

Remarquons que la somme S_n normalisée est égale à la moyenne M_n :

$$\frac{S_n - \mathbb{E}(S_n)}{\sigma(S_n)} = \frac{M_n - \mathbb{E}(M_n)}{\sigma(M_n)} = \frac{1}{\sigma\sqrt{n}} \left(\sum_{k=1}^n X_k - nm \right) \text{ que l'on notera } U_n$$

Théorème 3.5.1 (Lemme de Slutsky).

Soit $(X_n)_n$ et $(Y_n)_n$ deux suites de variables aléatoires définies sur le même espace de probabilité $(\Omega, \mathcal{A}, \mathcal{P})$. Soit X une variable aléatoire et $c \in \mathbb{R}$. On suppose que (X_n) converge en loi vers X et que (Y_n) converge en probabilité vers c . Alors (X_n, Y_n) converge en loi vers (X, c) et en particulier, on a

$$X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$$

$$Y_n \xrightarrow[n \rightarrow \infty]{P} c$$

alors

$$X_n + Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X + c$$

$$X_n Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} Xc$$

Dans le théorème précédent, il est important que (Y_n) converge en probabilité vers une constante. Le résultat deviendrait faux si on s'autorisait la convergence en probabilité vers une variable aléatoire Y quelconque.

Démonstration. Nous allons utiliser la caractérisation de la convergence en loi donnée par le théorème 3.4.1. Soit $(u, v) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ t.q,

$$\begin{aligned} |\phi_{(X_n, Y_n)}(u, v) - \phi_{(X, c)}(u, v)| &= |\mathbb{E}(e^{iuX_n + ivY_n}) - \mathbb{E}(e^{iuX + ivc})| \\ &= |\mathbb{E}(e^{iuX_n + ivY_n}) - \mathbb{E}(e^{iuX + ivY_n}) + \mathbb{E}(e^{iuX + ivY_n}) - \mathbb{E}(e^{iuX + ivc})| \end{aligned}$$

En utilisant la linéarité de l'espérance, cela devient :

$$|\phi_{(X_n, Y_n)}(u, v) - \phi_{(X, c)}(u, v)| = |\mathbb{E}((e^{iuX_n} - e^{iuX})e^{ivY_n}) + \mathbb{E}(e^{iuX}(e^{ivY_n} - e^{ivc}))|$$

D'après Cauchy-Schwarz, on a :

$$|\mathbb{E}((e^{iuX_n} - e^{iuX})e^{ivY_n})| = |\mathbb{E}(e^{iuX_n} - e^{iuX})| \times |\mathbb{E}(e^{ivY_n})|$$

et

$$|\mathbb{E}(e^{iuX}(e^{ivY_n} - e^{ivc}))| = |\mathbb{E}(e^{iuX})| \times |\mathbb{E}(e^{ivY_n} - e^{ivc})|$$

Or,

$$|e^{ivY_n}| \leq 1 \text{ et } |e^{iuX}| \leq 1$$

Donc, nous obtenons,

$$|\mathbb{E}((e^{iuX_n} - e^{iuX})e^{ivY_n})| = |\mathbb{E}(e^{iuX_n} - e^{iuX})| \times |\mathbb{E}(e^{ivY_n})| \leq |\mathbb{E}(e^{iuX_n} - e^{iuX})|$$

et

$$|\mathbb{E}(e^{iuX}(e^{ivY_n} - e^{ivc}))| = |\mathbb{E}(e^{iuX})| \times |\mathbb{E}(e^{ivY_n} - e^{ivc})| \leq |\mathbb{E}(e^{ivY_n} - e^{ivc})|$$

D'où

$$|\phi_{(X_n, Y_n)}(u, v) - \phi_{(X, c)}(u, v)| \leq |\mathbb{E}(e^{iuX_n} - e^{iuX})| + |\mathbb{E}(e^{ivY_n} - e^{ivc})| = |\phi_{X_n}(u) - \phi_X(u)| + |\mathbb{E}(e^{ivY_n} - e^{ivc})|$$

La convergence en loi de X_n vers X entraîne que le premier terme converge vers 0 lorsque $n \rightarrow \infty$, c'est à dire $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$. La continuité et la bornitude de $y \in \mathbb{R}^{d_2} \rightarrow f(y) = |e^{ivy} - e^{ivc}|$ et la convergence en loi de Y_n vers c entraîne que le second terme converge vers $f(c) = 0$, ce qui permet de conclure que (X_n, Y_n) converge en loi vers (X, c) . $\square$

Chapitre 4

Application des théorèmes de convergence (méthode de Monte-carlo)

4.1 Introduction

La méthode de Monte-Carlo est une technique mathématique et informatique utilisée pour estimer des valeurs inconnues à travers des procédés aléatoires, c'est à dire des techniques probabilistes. Le nom de cette méthode fait allusion aux jeux de hasard pratiqués à Monte-Carlo.

La méthode de Monte Carlo a été utilisée dans nombreux secteurs scientifiques et technologiques. Depuis lors, elle a trouvé des applications dans divers domaines allant de la finance à la physique en passant par l'ingénierie et la biologie. Cette technique consiste à résoudre des problèmes centrés sur le calcul d'une valeur numérique.

4.2 Principe de la méthode de Monte-carlo

La méthode de Monte-Carlo est une méthode numérique qui repose sur la simulation de variables aléatoires indépendantes.

Par la loi forte des grands nombres, la moyenne empirique d'un échantillon $(X_1, X_2, \dots, X_n)$ de X converge vers l'espérance $\mathbb{E}(X)$, On approxime alors $\mathbb{E}(X)$ par

$$\mathbb{E}(X) = \frac{1}{n}(X_1 + X_2 + \dots + X_n)$$

L'erreur est contrôlée par le théorème de limite centrale c'est à dire l'erreur se normalise à la vitesse $\sqrt{n}$ et converge en loi vers une loi normale centrée de variance $V(X)$.

4.3 Calcul d'intégrale par la méthode de Monte Carlo

Soit $g(x)$ une fonction intégrable sur $[0,1]$ dont on désire calculer l'intégrale $I = \int_0^1 g(x)dx$ (si les bornes d'intégration ne sont pas 0 et 1, on peut toujours s'y ramener grace à un changement de variable).

Si X désigne une variable aléatoire de loi de probabilité uniforme sur $[0,1]$, la variable aléatoire $Y = g(X)$ admet comme espérance mathématique, d'après le théorème du transfert

$$\mathbb{E}(Y) = I = \int_0^1 g(x)dx$$

La loi forte des grands nombres va nous fournir une méthode probabiliste pour calculer l'intégrale I . En effet, si X_n est une suite de variables aléatoires indépendantes de même loi de probabilité uniforme sur $[0,1]$, $g(X_k)$ est aussi une suite de variables aléatoires indépendantes de même loi de probabilité et par suite la variable aléatoire $M_n = \frac{1}{n} \sum_{k=1}^n g(X_k)$ converge presque sûrement vers $\mathbb{E}[g(X_k)] = I$.

Il suffit ainsi de considérer une suite de nombres au hasard $\{x_1, \dots, x_n\}$ pour construire une approximation $\hat{I}(x_1, \dots, x_n) = \frac{1}{n} \sum_{k=1}^n g(x_k)$ de l'intégrale I t.q :

$$\hat{I}(x_1, \dots, x_n) \xrightarrow{P.s} I$$

Le théorème de limite centrale permet d'estimer la précision de cette approximation puisque

$$\frac{M_n - \mathbb{E}(M_n)}{\sigma(M_n)} \xrightarrow{\mathcal{L}} U \text{ de la loi } \mathcal{N}(0, 1)$$

La variable M_n suit alors une loi de probabilité normale $\mathcal{N}(\mathbb{E}(M_n), \sigma^2(M_n))$ avec $\mathbb{E}(M_n) = I$ et

$$\sigma^2(M_n) = \frac{\sigma^2}{n} \text{ avec } \sigma^2 = V(g(X_n)) = \mathbb{E}[(g(X_n))^2] - (\mathbb{E}[g(X_n)])^2 = \int_0^1 (g(x))^2 dx - I^2$$

4.4 Accélération par échantillonnage pondéré

Une autre méthode d'améliorer la précision dans le calcul de I est d'utiliser un générateur de variables aléatoires dont la loi de probabilité n'est plus uniforme sur $[0,1]$.

En effet, I peut se mettre sous la forme :

$$I = \int_0^1 \frac{g(x)}{f_X(x)} f_X(x) dx$$

où $f_X(x)$ désigne la densité de probabilité d'une variable aléatoire X définie sur $[0,1]$

Dans ce cas, la variable aléatoire $Y = \frac{gX(x)}{f_X(x)}$ où X désigne une variable aléatoire de densité $f_X(x)$, admet comme espérance I et la variable aléatoire

$$M_n = \frac{1}{n} \sum_{k=1}^n \frac{g(x_k)}{f_X(x_k)}$$

converge presque sûrement vers $\mathbb{E}(Y) = I$ Il suffit donc de considérer un générateur de variable aléatoires X de densité de probabilité $f_X(x_k)$ définie sur $[0,1]$ $\{x_1, \dots, x_n\}$ pour construire une nouvelle approximation $\hat{I}(x_1, \dots, x_n) = \frac{1}{n} \sum_{k=1}^n g(x_k)$ de l'intégrale I t.q :

$$\sigma^2 = \int_0^1 \frac{g^2(x)}{f_X^2(x)} f_X(x) dx - \left[\frac{g(x)}{f_X(x)} f_X(x) \right]^2$$

4.5 Algorithmes

4.5.1 problèmes

Exemple 4.5.1. *Estimation de la Valeur de π en utilisant la Méthode de Monte-Carlo*

Objectif :

L'objectif de cet exercice est d'utiliser la méthode de Monte-Carlo pour estimer la valeur de π . Pour ce faire, nous allons générer un grand nombre de points aléatoires dans un carré de côté 2 centré à l'origine. Nous devons ensuite vérifier combien de ces points tombent à l'intérieur d'un cercle de rayon 1, également centré à l'origine. En utilisant la proportion de points à l'intérieur du cercle par rapport au nombre total de points générés, nous pourrions estimer π . Plus précisément, si n est le nombre total de points générés et k est le nombre de points à l'intérieur du cercle, alors l'estimation de π est donnée par la formule $\pi \simeq 4 \times \frac{k}{n}$. nous allons écrire un programme en Python pour réaliser cette estimation et d'analyser comment la précision de l'estimation varie en fonction du nombre de points générés.

Comprendre le Problème :

- La surface du cercle est $\pi \times 1^2 = \pi$.
- La surface du carré est $2 \times 2 = 4$.
- $\pi \simeq 4 \times \frac{k}{n}$ où k est le nombre de points à l'intérieur du cercle et n est le nombre total de points.
- Chaque point a des coordonnées (x,y) où x et y sont des nombres aléatoires entre -1 et 1.
- un point (x,y) est dans le cercle si $x^2 + y^2 \leq 1$
- Générer un certain nombre de points (par exemple, 10 000 points).

Algorithme :

Listing 4.1 – Algorithme pour l'estimation de π

```
fonction estimer-pi(n):
    nbre-des-pnts = 0
    pour i de 1 a n faire:
        x = nombre aleatoire entre -1 et 1
        y = nombre aleatoire entre -1 et 1
        si (x^2 + y^2 <= 1) alors:
            nbre-des-pnts = nbre-des-pnts + 1
    fin si
fin pour
pi = 4 * {nbre-des-pnts} / n
retourner pi
fin fonction
```


Listing 4.2 – Estimation de π par la méthode de Monte Carlo en Python

```
import numpy as np
import random

def estimer_pi(n):
    nbre_des_points = 0

    for i in range(n):
        x = random.uniform(-1, 1)
        y = random.uniform(-1, 1)
        if x**2 + y**2 <= 1:
            nbre_des_points += 1

    return 4 * nbre_des_points / n

n = 10000
estimation_pi = estimer_pi(n)
print(f"Estimation de $\pi$ avec {n} points : {estimation_pi}")
=3.1452
```

Questions :

1. Qu'observez-vous en augmentant le nombre de points n ?
2. Comparez votre estimation de π avec la valeur réelle de π ?
3. Quels facteurs pourraient influencer la précision de votre estimation ?

Réponses

1. En augmentant le nombre de points n , l'estimation de π devient plus précise. Avec un nombre plus élevé de points, la proportion de points dans le cercle par rapport au total des points converge vers la valeur théorique de $\frac{\pi}{4}$. Cela s'explique par la loi des grands nombres en probabilité, qui stipule que la moyenne des résultats d'un grand nombre d'essais indépendants approche la valeur attendue.
2. La valeur réelle de π est 3.1415926. L'estimation obtenue avec 10 000 points est 3.1452. Cette estimation est très proche de la valeur réelle mais les petites différences sont dues à la précision limitée par le nombre de points utilisés.
3. Plusieurs facteurs peuvent influencer la précision de l'estimation comme le Nombre de Points et La qualité du générateur de nombres aléatoires car les générateurs de mauvaise qualité peuvent introduire des biais.

Dans cet exercice on a utilisé plusieurs boucles comme :

- La boucle " for i in range(n)" pour répéter l'opération de génération de points
- la boucle "if " pour vérifier si le point (x,y) se trouve à l'intérieur du cercle de rayon 1.

4.6 Fondements des Méthodes Monte-Carlo en Physique Médicale

Dans le domaine de la physique médicale, les techniques Monte-Carlo proposent une approche simple : la résolution de problème macroscopique complexe (le calcul de la distribution de dose absorbée) par l'étude des mécanisme élémentaires au niveau microscopique

(la simulation du transport des particules et leurs interactions).

Les méthodes de Monte-carlo reposent ainsi sur la connaissance fine des interactions fondamentales rayonnements. En effet, tous les événements de l'histoire d'une particule (interactions, distances de parcours, directions ou pertes d'énergies) seront échantillonnés à partir des fonction de densité de probabilité de chacun de ces événements.

Pour échantillonner correctement ces grandeurs il faut utiliser des nombres aléatoires et répéter l'opération un nombre de fois suffisant. En d'autres termes, pour avoir une simulation de Monte-carlo de dose absorbée décrivant bien la réalité, il faut simuler un nombre suffisant d'histoires aléatoirement générées suivant les lois physiques des rayonnements.

Exemple 4.6.1. *Simulation Monte Carlo pour l'Absorption de Dose.*

Objectif :

Simuler l'absorption de dose d'un faisceau de particules dans un matériau en utilisant la méthode de Monte Carlo, et analyser les résultats pour montrer la convergence statistique et la réduction du bruit grâce aux lois des grands nombres et au théorème central limite.

Comprendre le Problème :

- *Considérons un faisceau de particules dans un matériau, chacun subit par des interactions aléatoires selon une section efficace différentielle donnée et chaque interaction cause une perte d'énergie.*
- *Pour chaque particule, simulons les interactions successives jusqu'à ce que la particule ait perdu toute son énergie et calculons la dose absorbée en fonction de l'énergie déposée dans le matériau.*
- *Répètons la simulation pour différents nombres N en calculant la moyenne et la variance de la dose absorbée pour chaque N .*
- *Analysons comment le bruit statistique (écart-type de la moyenne) décroît avec l'augmentation du nombre de particules simulées, conformément à la relation $\text{bruit} \sim \frac{1}{\sqrt{n}}$*
- *Nous allons définir une fonction "simuler-particule" qui simule l'histoire d'une particule dans le matériau et une autre appelée "executer-simulation" qui permet d'exécuter la simulation pour un nombre donné de particules N et retourne la dose moyenne absorbée et son écart-type.*

Algorithme :

Listing 4.3 – Simulation Monte Carlo de l’Absorption de Dose en Physique des Particules

```
N_particules = [100, 1000, 10000]
INITIALISER energie_init = 10.0
INITIALISER chemin_libre = 1.0
INITIALISER perte_energie_par_interaction = 0.1

DEFINIR fonction simuler_particule(energie_init, chemin_libre,
    ↪ perte_energie_par_interaction)
    energie = energie_init
    dose_absorbee = 0.0
    TANT QUE energie > 0
        distance = EXPONENTIAL(chemin_libre)
        perte_energie = NORMAL(perte_energie_par_interaction,
            ↪ 0.02)
        perte_energie = MAX(MIN(energie, perte_energie), 0)
        energie -= perte_energie
        dose_absorbee += perte_energie
    RETOURNER dose_absorbee

DEFINIR fonction executer_simulation(N)
INITIALISER doses = []
    POUR i de 1 a N
        dose = simuler_particule(energie_init, chemin_libre,
            ↪ perte_energie_par_interaction)
        AJOUTER dose a doses
    RETOURNER MEAN(doses), STD(doses)

INITIALISER resultats = {}
POUR chaque N dans N_particules
    RANDOM_SEED()
    dose_moyenne, ecart_type_dose = executer_simulation(N)
    resultats[N] = (dose_moyenne, ecart_type_dose)

POUR chaque N dans N_particules
    dose_moyenne, ecart_type_dose = resultats[N]
    AFFICHER "N =", N, ": Dose Moyenne =", dose_moyenne, ", Ecart
        ↪ Type =", ecart_type_dose, ", Ecart Type de la Moyenne =
        ↪ ", ecart_type_dose/np.sqrt(N)

TRACER graph(moyennes, erreurs, N_particules)
```

Listing 4.4 – Simulation Monte Carlo de l’Absorption de Dose en Physique en python

```
import numpy as np
import matplotlib.pyplot as plt

N_particules = [100, 1000, 10000]
energie_init = 10.0
chemin_libre = 1.0
perte_energie_par_interaction = 0.1

def simuler_particule(energie_init, chemin_libre,
    ↪ perte_energie_par_interaction):
    energie = energie_init
    dose_absorbee = 0.0
    while energie > 0:
        distance = np.random.exponential(chemin_libre)
        perte_energie = np.random.normal(
            ↪ perte_energie_par_interaction, 0.02)
        perte_energie = max(min(energie, perte_energie), 0)
        energie -= perte_energie
        dose_absorbee += perte_energie
    return dose_absorbee

def executer_simulation(N):
    doses = [simuler_particule(energie_init, chemin_libre,
        ↪ perte_energie_par_interaction) for i in range(N)]
    return np.mean(doses), np.std(doses)

resultats = {}
for N in N_particules:
    np.random.seed()
    dose_moyenne, ecart_type_dose = executer_simulation(N)
    resultats[N] = (dose_moyenne, ecart_type_dose)

for N in N_particules:
    dose_moyenne, ecart_type_dose = resultats[N]
    print(f"N = {N}: Dose Moyenne = {dose_moyenne}, Ecart Type =
        ↪ {ecart_type_dose}, Ecart Type de la Moyenne = {
        ↪ ecart_type_dose/np.sqrt(N)}")

moyennes = [resultats[N][0] for N in N_particules]
erreurs = [resultats[N][1] / np.sqrt(N) for N in N_particules]


plt.errorbar(N_particules, moyennes, yerr=erreurs, fmt='o')
plt.xscale('log')
plt.xlabel('Nombre de Particules')
plt.ylabel('Dose Moyenne Absorbee')
plt.title('Convergence de la Simulation Monte Carlo')
plt.show()
```

les resultats obtenues

N = 100: Dose Moyenne = 10.0, Ecart Type = 4.131700617056214e-15, Ecart Type de la Moyenne = 4.1317006170562136e-16
N = 1000: Dose Moyenne = 10.0, Ecart Type = 3.830510780184651e-15, Ecart Type de la Moyenne = 1.211313866721207e-16
N = 10000: Dose Moyenne = 10.0, Ecart Type = 3.866872209717207e-15, Ecart Type de la Moyenne = 3.866872209717207e-17

Interprétation des résultats

Les résultats montrent que la dose moyenne absorbée reste constante à 10.0 unités quelle que soit la taille de l'échantillon N. Les écarts types sont extrêmement petits, indiquant une très faible variabilité entre les doses absorbées par différentes particules. Enfin, les écarts types de la moyenne diminuent avec l'augmentation de N, ce qui est attendu car plus le nombre de particules est grand, plus la moyenne échantillonnée est précise. En résumé, ces résultats illustrent que la simulation est très précise et stable, avec des doses moyennes absorbées cohérentes, surtout lorsque le nombre de particules simulées est élevé.



Interprétation du graphique

Le graphique montre trois points alignés horizontalement à une dose moyenne absorbée de 10, ce qui confirme que la dose moyenne absorbée reste constante indépendamment du nombre de particules simulées. Les barres d'erreur (très petites dans ce cas) illustrent la précision de la moyenne estimée.

4.7 Environnement de travail

4.7.1 Anaconda

Nous avons utilisé anaconda présenté par la figure ci-jointe, qui est une distribution de logiciels open source permet la programmation en langages python et R. En effet, c'est une plateforme complète pour les sciences de données. Elle est particulièrement utile dans le domaine de l'intelligence artificielle parce qu'elle offre une variété de bibliothèques pour la préparation, la manipulation, la modélisation et l'évaluation des données.



En outre, Anaconda est un ensemble de logiciels contenant de nombreux outils et bibliothèques pour la programmation en Python. Parmi ces outils se trouve Jupyter présenté par la figure ci-dessous, qui permet de créer et partager des documents interactifs contenant du code, des graphiques et du texte.



4.7.2 La bibliothèque NumPy

NumPy est une bibliothèque Python qui fournit des solutions puissantes de stockage de données, permettant le stockage de grandes quantités de données tout en consommant moins de mémoire. Il offre des fonctionnalités avancées telles que des tableaux multidimensionnels, ainsi qu'une gamme d'outils mathématiques tels que l'algèbre linéaire, des fonctions spéciales et des routines statistiques.



4.7.3 Matplotlib

Matplotlib est une bibliothèque Python gratuite, peut être utilisée pour générer des tracés, des histogrammes, des graphiques à barres et d'autres types de graphiques. Cet outil complet permet aux utilisateurs de créer des visualisations de données détaillées et complexes.



Conclusion et perspectives

Ce projet nous a permis de plonger dans le monde fascinant des théorèmes de convergence et de la méthode de Monte-Carlo. Nous avons découvert comment ces concepts peuvent être appliqués de manière pratique grâce à des outils de programmation comme Python. En observant la convergence de nos résultats et en évaluant leur précision, nous avons acquis une compréhension approfondie de la manière dont ces méthodes peuvent être utilisées pour résoudre une grande variété de problèmes.

L'avenir de l'application de la méthode de Monte Carlo en radiothérapie s'annonce prometteur grâce aux progrès continus en informatique et en technologies de simulation. Les développements dans le calcul parallèle permettent d'accélérer significativement les simulations Monte Carlo, rendant cette technique de plus en plus accessible pour une utilisation clinique routinière. De plus, l'intégration de l'intelligence artificielle et des techniques d'apprentissage automatique pourrait optimiser les simulations, en réduisant le temps de calcul tout en maintenant une haute précision.

Références

- [1] Jérôme ESCOFFIER, PROBABILITÉS et STATISTIQUES pour le CAPES et l'Agrégation Interne
- [2] Charles-Michel Marle, Philippe Pilibossian, MATHÉMATIQUES à l'Université
- [3] Jean-Pierre DELMAS, INTRODUCTION AUX PROBABILITÉS
- [4] Site officiel de Aide-mémoire Statistique et probabilités, adresse : <https://ia601900.us.archive.org/28/items/EstimationEtInfrenceEnConometrie/Aide-m%C3%A9moire%20Statistique%20et%20probabilit%C3%A9s.pdf>,
- [5] Site officiel de poly, adresse : <https://cermics.enpc.fr/~jourdain/probastat/poly.pdf>
- [6] Site officiel de LamthodeMonteCarloetsesapplications, adresse : https://www.researchgate.net/publication/310828308_La_methode_Monte_Carlo_et_ses_applications?enrichId=rgreq-28a2f5579dd6b59b605281a1683fb81a-XXX&enrichSource=Y292ZXJQYWdl0zMxMDgyODMwODtBUzo0MzIzOTYzMjg4MDQzNTJAMTQ4MDEwMjcyNjAwOA%3D%3D&el=1_x_2&esc=publicationCover.Pdf
- [7] Site officiel de poly, adresse : <https://theses.hal.science/tel-03209752.pdf>